

UNIVERSITÉ DE YAOUNDE I

ÉCOLE NATIONALE SUPÉRIEURE
POLYTECHNIQUE DE YAOUNDE

DEPARTEMENT DE GENIE
INFORMATIQUE



UNIVERSITY OF YAOUNDE I

NATIONAL ADVANCED SCHOOL
OF ENGINEERING OF YAOUNDE

DEPARTMENT OF COMPUTER
ENGINEERING

CONCEPTION D'UNE ARCHITECTURE MLOps Cloud SUR AWS

Mémoire de fin d'études

Présenté et soutenu par

TAMBOU DJOMOU FRANCK DONALD

Matricule : 23P732

En vue de l'obtention du :

**DIPLÔME D'INGÉNIEUR DE CONCEPTION EN ARTS NUMÉRIQUES
OPTION : ARTS ET INTELLIGENCE ARTIFICIELLE**

Sous la supervision de :

Pr Thomas BOUETOU BOUETOU, Professeur, UYI/ENSPY

Dr Austin WAFFO, Chargé de cours, UYI/ENSPY

Ing. Junior TEMGOUA, CTO, DESEMITS LLC

Devant le jury composé de :

Président : **Pr X**, Maître de conférence, UYI/ENSPY

Examineur : **Dr X**, Chargé de cours, UYI/ENSPY

Rapporteur 1 : **Pr Thomas BOUETOU BOUETOU**, Professeur, UYI/ENSPY

Rapporteur 2 : **Dr Austin WAFFO**, Chargé de cours, UYI/ENSPY

Invité : **Mme Fridoline MBIA**, RH, TECTRA

Année académique 2025-2026

Mémoire soutenu en Septembre 2026



CONCEPTION D'UNE ARCHITECTURE MLOPS CLOUD SUR AWS

Mémoire de fin d'études

Présenté et soutenu par

TAMBOU DJOMOU FRANCK DONALD

Matricule : 23P732

En vue de l'obtention du :

**DIPLÔME D'INGÉNIEUR DE CONCEPTION EN ARTS NUMÉRIQUES
OPTION : ARTS ET INTELLIGENCE ARTIFICIELLE**

Année académique 2025-2026

Mémoire soutenu en Septembre 2026

DÉDICACE



À Mes Parents



REMERCIEMENTS

La réalisation de ce mémoire n'aurait pas été possible sans le soutien et les conseils de nombreuses personnes. Nous leur adressons notre sincère gratitude, en particulier à :

- ☛ **Dieu Tout-Puissant**, pour la vie, la santé, la force, la sagesse et les nombreuses grâces qu'Il nous a accordées tout au long de ce parcours.
- ☛ **Pr X**, qui nous fait l'honneur de présider ce jury.
- ☛ **Pr X**, qui a accepté d'examiner ce travail et dont les observations et recommandations contribueront à son amélioration.
- ☛ **Pr Thomas BOUETOU** et **Dr Austin WAFFO KOUHOUE**, qui ont accepté d'être les rapporteurs de ce mémoire et pour l'intérêt qu'ils portent à ce travail.
- ☛ **Ing. Junior TEMGOUA**, notre encadreur professionnel et *Chief Technology Officer* de **DESEMITS LLC**, pour sa disponibilité, son accompagnement, son expertise technique ainsi que les nombreuses connaissances professionnelles qu'il nous a transmises durant ce stage.
- ☛ **Prof. Raoul Domingo AYISSI**, Directeur de l'École Nationale Supérieure Polytechnique de Yaoundé, pour la qualité de la formation dispensée au sein de cette prestigieuse institution.
- ☛ **Pr Thomas BOUETOU**, Chef du Département de Génie Informatique de l'École Nationale Supérieure Polytechnique de Yaoundé, pour son engagement constant dans la formation des futurs ingénieurs.
- ☛ L'ensemble des responsables et collaborateurs de **DESEMITS LLC**, pour leur accueil, leur confiance et le cadre professionnel enrichissant qui nous a permis de mener à bien ce projet de fin d'études.
- ☛ Tout le corps enseignant de l'École Nationale Supérieure Polytechnique de Yaoundé, pour la qualité des enseignements dispensés et les compétences acquises durant notre formation d'ingénieur.
- ☛ Nos parents, ainsi que toute notre famille, pour leur amour, leurs sacrifices, leurs prières, leurs encouragements et leur soutien indéfectible tout au long de notre parcours.



👉 Nos camarades de promotion, nos amis ainsi que toutes les personnes qui, de près ou de loin, ont contribué à la réalisation de ce mémoire par leurs conseils, leur soutien ou leurs encouragements.

Enfin, nous adressons nos sincères remerciements à toutes les personnes qui, directement ou indirectement, ont contribué à l'aboutissement de ce travail et que nous n'avons pu citer individuellement.



RÉSUMÉ

L'industrialisation des modèles d'intelligence artificielle représente aujourd'hui un défi majeur pour les organisations souhaitant déployer des solutions performantes, fiables et soutenables en production, où le passage à l'échelle se heurte souvent à la volumétrie croissante des données et à la complexité de l'automatisation. Ce mémoire porte sur la conception et l'implémentation d'une architecture Cloud orientée MLOps dédiée au passage à l'échelle d'un modèle de vision par ordinateur appliqué à la détection d'anomalies sur des cultures agricoles. La solution proposée repose sur les services d'Amazon Web Services (AWS) et applique un découplage physique strict entre l'ingénierie des données massives d'une part, et la plateforme MLOps d'autre part. Le pipeline de traitement distribue l'ingestion, le nettoyage et la réduction de dimensionnalité par Analyse en Composantes Principales (ACP) à l'aide d'un cluster éphémère Amazon EMR sous Apache Spark (PySpark), tandis que le cycle de vie du modèle d'apprentissage profond est entièrement orchestré via la plateforme Amazon SageMaker, incluant SageMaker Studio, le Model Registry pour la gouvernance et le déploiement d'un point de terminaison (Endpoint) d'inférence en temps réel. L'infrastructure réseau isolée sous Amazon VPC ainsi que la gestion des accès et rôles AWS IAM sont entièrement provisionnées en tant que code via Terraform et déployées automatiquement à l'aide de pipelines d'intégration et de livraison continues GitHub Actions. Les expérimentations menées confirment la viabilité technique et financière de cette architecture, démontrant une élimination complète des verrous de saturation mémoire locale, une latence moyenne d'inférence de 45 ms sur le point de terminaison, et une maîtrise budgétaire rigoureuse (FinOps) s'appuyant sur l'utilisation d'instances EC2 Spot et de ressources temporaires, pour un coût mensuel global mesuré à 117,95 \$, posant ainsi des fondations robustes et hautement sécurisées pour l'exploitation pérenne de l'intelligence artificielle.

Mots-clés : Intelligence artificielle, MLOps, Cloud Computing, Amazon Web Services, Amazon EMR, Amazon S3, Amazon SageMaker, Apache Spark, PySpark, Infrastructure as Code, Terraform, GitHub Actions, FinOps, Scalabilité.

ABSTRACT

The industrialisation of artificial intelligence models represents a major challenge today for organisations wishing to deploy high-performance, reliable, and sustainable solutions in production, where scaling up often faces the hurdles of increasing data volume and the complexity of automation. This thesis focuses on the design and implementation of a Cloud-based MLOps architecture dedicated to scaling up a computer vision model applied to crop anomaly detection on agricultural fields. The proposed solution relies on Amazon Web Services (AWS) and implements a strict physical decoupling between massive data engineering on one side, and the MLOps platform on the other. The processing pipeline distributes ingestion, cleaning, and dimensionality reduction through Principal Component Analysis (PCA) using an ephemeral Amazon EMR cluster under Apache Spark (PySpark), while the deep learning model life cycle is fully orchestrated via the Amazon SageMaker platform, including SageMaker Studio, the Model Registry for governance, and the deployment of a point of termination (Endpoint) for real-time inference. The isolated network infrastructure under Amazon VPC as well as AWS IAM access and role management are fully provisioned as code via Terraform and automatically deployed using GitHub Actions continuous integration and continuous delivery pipelines. The experiments conducted confirm the technical and financial viability of this architecture, demonstrating a complete elimination of local memory saturation bottlenecks, an average inference latency of 45 ms on the endpoint, and a rigorous budget management (FinOps) relying on the use of EC2 Spot instances and temporary resources, for a total monthly cost measured at 117.95 \$, thus laying down robust and highly secure foundations for the sustainable exploitation of artificial intelligence.

Keywords : Artificial Intelligence, MLOps, Cloud Computing, Amazon Web Services, Amazon EMR, Amazon S3, Amazon SageMaker, Apache Spark, PySpark, Infrastructure as Code, Terraform, GitHub Actions, FinOps, Scalability.

TABLE DES MATIÈRES

Dédicace	i
Remerciements	ii
Résumé	iv
Abstract	v
Table des matières	vi
Liste des figures	viii
Liste des tableaux	ix
Liste des abréviations et sigles	x
Glossaire	xii
Introduction générale	1
1 Généralités et état de l'art	4
1.1 Généralités	5
1.1.1 Le MLOps (Machine Learning Operations)	5
1.1.2 Le Cloud Computing : Catalyseur de l'IA à grande échelle	7
1.2 État de l'art	10
1.2.1 Revue de la littérature scientifique (Approche académique)	10
1.2.2 Retours d'expérience et architectures industrielles (Cas d'étude)	12
1.2.3 Bilan de l'état de l'art et Positionnement technologique du projet	24
2 Méthodologie de conception	27
2.1 Planification du projet	28
2.2 Analyse du problème et définition des besoins	29
2.2.1 Analyse du problème	29
2.2.2 Besoins fonctionnels	29

2.2.3	Besoins non fonctionnels	32
2.2.4	Acteurs du système	33
2.2.5	Diagramme de cas d'utilisation	34
2.3	Conception de la solution	35
2.3.1	Architecture logique	35
2.3.2	Architecture physique	37
2.4	Résumé du chapitre	39
3	Implémentation et résultats	40
3.1	Infrastructure et automatisation	41
3.1.1	Provisionnement automatisé par Terraform	41
3.1.2	Structuration et sécurité du Data Lake (Amazon S3)	43
3.1.3	Intégration CI/CD via GitHub Actions	44
3.2	Implémentation du pipeline Data Engineering	46
3.2.1	Configuration du cluster distribué éphémère	46
3.2.2	Développement du traitement d'images distribué sous PySpark	48
3.3	Implémentation de la plateforme MLOps	49
3.3.1	Espace de travail collaboratif (SageMaker Studio)	49
3.3.2	Pipeline d'entraînement et registre de modèles (Model Registry)	50
3.3.3	Déploiement du service d'inférence (SageMaker Endpoint)	51
3.4	Résultats, métriques et analyse des coûts	52
3.4.1	Protocole expérimental et supervision en temps réel	52
3.4.2	Évaluation technique des performances	53
3.4.3	Analyse financière et évaluation FinOps	53
3.5	Résumé du chapitre	55
	Conclusion générale et Perspectives	57
	Références bibliographiques	59

LISTE DES FIGURES

2.1	Modélisation fonctionnelle du flux de données vers le Data Lake	29
2.2	Flux fonctionnel d'Intégration et de Déploiement Continus (CI/CD)	31
2.3	Diagramme de cas d'utilisation du système hybride (Data Engineering & MLOps) . .	35
2.4	Architecture logique du pipeline de traitement distribué et d'orchestration MLOps . .	37
2.5	Architecture physique détaillée de la solution MLOps sur Amazon Web Services . . .	39
3.1	Extrait du script de configuration Terraform (Fichiers HCL pour le réseau)	42
3.2	Configuration réseau sous Amazon VPC et isolation des sous-réseaux	43
3.3	Organisation de l'arborescence du Data Lake dans le bucket Amazon S3	44
3.4	Historique d'exécution du pipeline de provisionnement d'infrastructure IaC dans GitHub Actions	45
3.5	Étape d'exécution d'un pipeline de provisionnement d'infrastructure IaC dans GitHub Actions Terraform apply	46
3.6	Console AWS présentant le statut actif et la topologie du cluster Amazon EMR (1 Master / 4 Workers)	47
3.7	Terminal de connexion sécurisée au nœud maître (Master Node) d'Amazon EMR via SSH	48
3.8	Espace de travail Jupyter actif au sein de la console Amazon SageMaker Studio . . .	50
3.9	Interface du registre de modèles (Model Registry) présentant les versions et l'historique d'approbation	51
3.10	Interface Apache Spark UI présentant le suivi d'exécution des tâches distribuées sur le cluster	53

LISTE DES TABLEAUX

1.1	Cartographie de l'Architecture de Référence MLOps (Netflix vs AWS)	15
1.2	Cartographie de l'Architecture MLOps Sécurisée (Secteur Bancaire / FSI)	18
1.3	Cartographie de l'Architecture Cloud à très faible latence (Riot Games / AWS)	20
1.4	Cartographie de l'Architecture et des Services Cloud (Expedia Group)	22
1.5	Cartographie de l'Architecture de Référence (AWS, Terraform, GitHub)	24
2.1	Exigences fonctionnelles liées au prétraitement des images agricoles	30
2.2	Exigences fonctionnelles liées à la Plateforme MLOps	31
2.3	Matrice de synthèse des besoins non fonctionnels de l'architecture	33
2.4	Cartographie des acteurs et de leurs responsabilités dans le système	34
3.1	Structuration logique et rôles des répertoires du Data Lake Amazon S3	44
3.2	Répartition des coûts mensuels réels par service AWS (approche FinOps)	54
3.3	Matrice d'évaluation technique et financière finale du système	55

LISTE DES ABRÉVIATIONS ET SIGLES

- **ACP** : Analyse en Composantes Principales
- **API** : Application Programming Interface (Interface de programmation d'application)
- **AWS** : Amazon Web Services
- **CACE** : Changing Anything Changes Everything (Modifier une chose modifie tout)
- **CD** : Continuous Deployment / Delivery (Déploiement / Livraison continu)
- **CI** : Continuous Integration (Intégration continue)
- **CNN** : Convolutional Neural Network (Réseau de neurones convolutifs)
- **CPU** : Central Processing Unit (Unité centrale de traitement)
- **CT** : Continuous Training (Entraînement continu)
- **DAG** : Directed Acyclic Graph (Graphe orienté acyclique)
- **DevOps** : Development and Operations (Développement et Opérations)
- **DL** : Deep Learning (Apprentissage profond)
- **EC2** : Elastic Compute Cloud
- **EMR** : Elastic MapReduce
- **FinOps** : Financial Operations (Gestion financière des ressources Cloud)
- **GCP** : Google Cloud Platform
- **GPU** : Graphics Processing Unit (Processeur graphique)
- **HCL** : HashiCorp Configuration Language (Langage de configuration de Terraform)
- **HTTP** : Hypertext Transfer Protocol
- **IA** : Intelligence Artificielle
- **IaC** : Infrastructure as Code (Infrastructure en tant que code)
- **IaaS** : Infrastructure as a Service (Infrastructure en tant que service)
- **IAM** : Identity and Access Management (Gestion des identités et des accès)
- **JSON** : JavaScript Object Notation
- **KMS** : Key Management Service (Service de gestion des clés d'AWS)



- **KS** : Kolmogorov-Smirnov (Test statistique de Kolmogorov-Smirnov pour la dérive de données)
- **ML** : Machine Learning (Apprentissage automatique)
- **MLOps** : Machine Learning Operations (Opérations d'apprentissage automatique)
- **NAT** : Network Address Translation (Traduction d'adresses réseau pour les NAT Gateways)
- **PaaS** : Platform as a Service (Plateforme en tant que service)
- **PCA** : Principal Component Analysis (Équivalent anglais de l'ACP)
- **PoC** : Proof of Concept (Preuve de concept / Expérimentation)
- **RAM** : Random Access Memory (Mémoire vive)
- **REST** : Representational State Transfer
- **RGPD** : Règlement Général sur la Protection des Données
- **S3** : Simple Storage Service (Service de stockage d'Amazon)
- **SaaS** : Software as a Service (Logiciel en tant que service)
- **SLA** : Service Level Agreement (Accord de niveau de service)
- **SLI** : Service Level Indicator (Indicateur de niveau de service)
- **SLO** : Service Level Objective (Objectif de niveau de service)
- **SRE** : Site Reliability Engineering (Ingénierie de la fiabilité des sites)
- **SSH** : Secure Shell (Protocole de connexion sécurisée au cluster)
- **UDF** : User Defined Function (Fonction personnalisée de l'utilisateur sous Spark)
- **UML** : Unified Modeling Language (Langage de modélisation unifié)
- **VPC** : Virtual Private Cloud (Réseau privé virtuel)
- **YARN** : Yet Another Resource Negotiator (Gestionnaire de ressources Spark sous EMR)



GLOSSAIRE

- **Cluster (Grappe de serveurs)** : Ensemble d'ordinateurs virtuels ou physiques (nœuds) interconnectés qui travaillent de concert pour exécuter des tâches de calcul distribué, comme le permet le service Amazon EMR.
- **Cloud Computing (Informatique en nuage)** : Fourniture à la demande de ressources informatiques (puissance de calcul, stockage, bases de données, réseaux) via Internet, avec une tarification basée sur la consommation réelle [1].
- **Continuous Training (CT - Entraînement continu)** : Pratique spécifique au MLOps consistant à automatiser le réentraînement d'un modèle de Machine Learning en production afin de corriger la dérive des données et de maintenir sa précision au fil du temps [2, 3].
- **Data Lake (Lac de données)** : Référentiel de stockage unique et centralisé permettant de conserver des volumes massifs de données brutes ou structurées sous leur format d'origine, garantissant le découplage physique entre le stockage et le calcul [4].
- **Dérive des données (Data Drift)** : Changement silencieux de la distribution statistique des données réelles reçues en production par rapport aux données utilisées lors de la phase d'entraînement, entraînant une dégradation inévitable de la précision du modèle [5, 6].
- **Dette technique cachée (Hidden Technical Debt)** : Accumulation de compromis de conception à court terme dans les systèmes d'apprentissage automatique, où le code algorithmique ne représente qu'une infime fraction d'une vaste infrastructure complexe de support difficile à maintenir [6].
- **FinOps (Financial Operations)** : Pratique de gestion financière appliquée au Cloud visant à aligner les équipes techniques, financières et métiers pour maximiser la valeur opérationnelle tout en minimisant les coûts par l'usage de ressources éphémères et d'instances Spot [4, 7].
- **Infrastructure as Code (IaC - Infrastructure en tant que code)** : Méthode permettant de définir, versionner et déployer automatiquement les ressources d'infrastructure d'un réseau ou d'un système Cloud à l'aide de fichiers de configuration déclaratifs (tels que Terraform) [8].



- **MLOps (Machine Learning Operations)** : Discipline d'ingénierie située à l'intersection de l'apprentissage automatique, de l'ingénierie des données et des pratiques DevOps, visant à standardiser et automatiser l'intégralité du cycle de vie des modèles en production [9].
- **Site Reliability Engineering (SRE - Ingénierie de la fiabilité des sites)** : Approche d'exploitation appliquant les principes du génie logiciel aux problématiques d'infrastructure, reposant sur des indicateurs précis de disponibilité, de performance et de fiabilité opérationnelle [6, 7].



INTRODUCTION GÉNÉRALE

CONTEXTE

L'intelligence artificielle (IA) et plus particulièrement l'apprentissage automatique (Machine Learning) connaissent aujourd'hui un essor fulgurant, transformant en profondeur la manière dont les organisations exploitent leurs données. Cependant, si le développement de modèles d'IA performants en laboratoire est devenu monnaie courante, leur passage à l'échelle et leur déploiement en environnement de production restent des défis technologiques majeurs. En effet, les modèles déployés sont confrontés à des volumes de données massifs et à une dégradation inévitable de leurs performances dans le temps, un phénomène connu sous le nom de dérive des données [5]. Pour surmonter ces obstacles, l'industrie s'oriente massivement vers le Cloud Computing, qui offre une puissance de calcul et de stockage à la demande, et vers les pratiques du MLOps (*Machine Learning Operations*). Le MLOps unifie le développement des systèmes d'apprentissage automatique et leur exploitation, permettant d'automatiser le cycle de vie des modèles, de leur entraînement initial jusqu'à leur supervision et leur réentraînement continu [5]. C'est dans ce contexte d'industrialisation que s'inscrit le besoin de concevoir des architectures robustes, capables de soutenir des pipelines de données complexes tout en garantissant la fiabilité et la reproductibilité des déploiements.

PROBLÉMATIQUE

Si le Cloud Computing et le MLOps offrent des outils puissants pour industrialiser l'intelligence artificielle, leur application concrète soulève des problématiques d'ingénierie critiques. Les architectures traditionnelles ou locales saturent rapidement face à l'augmentation des flux de données. De plus, un modèle figé perd inévitablement en précision face à l'évolution des données du monde réel. L'absence d'une boucle de rétroaction permettant l'apprentissage continu entraîne souvent une maintenance complexe, un déclin des prédictions et une explosion des coûts opérationnels [5].

Dans ce contexte, une question centrale émerge :



Problématique centrale

Comment concevoir une architecture MLOps Cloud sur AWS qui permette la continuité d'apprentissage d'un modèle et de garantir son passage à l'échelle face à des données massives, tout en optimisant les performances et les coûts d'exploitation ?

OBJECTIFS DU MEMOIRE

L'objectif principal de ce mémoire est de concevoir et d'implémenter une architecture Cloud MLOps sur AWS permettant l'industrialisation et l'apprentissage continu d'un modèle d'intelligence artificielle. Cela passera par les objectifs spécifiques suivants :

- Analyser et comparer les principales plateformes Cloud et approches MLOps existantes afin de justifier les choix technologiques retenus.
- Concevoir une architecture distribuée découplant strictement les ressources de stockage et les ressources de calcul pour garantir un passage à l'échelle optimal.
- Modéliser un pipeline automatisé intégrant l'ingestion de nouvelles données, la continuité d'apprentissage (réentraînement) et l'inférence du modèle.
- Déployer la solution sur AWS et évaluer ses performances techniques et financières (FinOps).

MÉTHODOLOGIE ET STRUCTURE DU MEMOIRE

Pour atteindre ces objectifs, nous avons suivi une approche méthodologique qui est la suivante :

- Effectuer une revue de la littérature afin de comprendre l'existant, de définir les concepts du Cloud et du MLOps, et de mieux appréhender les contours de notre projet ;
- Réaliser l'analyse des besoins fonctionnels et non fonctionnels pour définir le périmètre du système ;
- Effectuer une modélisation théorique de l'architecture logique et de l'architecture physique de la solution ;
- Implémenter la solution sur l'infrastructure AWS et élaborer un protocole d'expérimentation pour valider les résultats.

Le mémoire sera structuré comme suit :





👉 **Chapitre 1 : Généralités et état de l'art**

Dans ce chapitre, nous présentons dans un premier temps des généralités structurées autour de deux axes : le MLOps et le Cloud Computing (ses fonctions et ses limites juridiques et sécuritaires). Dans un second temps, nous dressons un état de l'art complet combinant une revue rigoureuse de la littérature scientifique récente et une analyse comparative des architectures MLOps industrielles de référence. Pour finir, nous établissons un bilan permettant de positionner et de justifier scientifiquement notre démarche d'ingénierie.

👉 **Chapitre 2 : Méthodologie**

Dans ce chapitre, nous présentons en détail la méthodologie adoptée pour la réalisation du projet. Nous exposons la méthodologie de développement, suivie d'une analyse approfondie du problème (besoins, acteurs, cas d'utilisation). Enfin, nous détaillons la conception de la solution à travers ses architectures logique et physique.

👉 **Chapitre 3 : Implémentation et résultats**

Dans ce dernier chapitre, nous présentons l'environnement d'implémentation et le déploiement de l'infrastructure sur AWS. Nous discutons ensuite des résultats expérimentaux obtenus, en analysant les performances de l'architecture, sa capacité de passage à l'échelle et son optimisation des coûts.

Nous terminons par une conclusion générale, qui présente le bilan de ce travail, ses limites et des propositions de perspectives pour les recherches futures.



GÉNÉRALITÉS ET ÉTAT DE L'ART

Ce chapitre s'articule autour de quatre axes principaux : les généralités théoriques sur le MLOps et le Cloud Computing dans un premier temps, suivies d'une revue rigoureuse de la littérature scientifique récente afin de poser les fondements théoriques de notre démarche. Nous analysons ensuite les architectures MLOps de référence déployées dans l'industrie à travers plusieurs cas d'étude, avant de conclure par un bilan global permettant de positionner et de justifier scientifiquement nos choix technologiques pour la suite de ce mémoire.

Sommaire

1.1	Généralités	5
1.1.1	Le MLOps (Machine Learning Operations)	5
1.1.2	Le Cloud Computing : Catalyseur de l'IA à grande échelle	7
1.2	État de l'art	10
1.2.1	Revue de la littérature scientifique (Approche académique)	10
1.2.2	Retours d'expérience et architectures industrielles (Cas d'étude)	12
1.2.3	Bilan de l'état de l'art et Positionnement technologique du projet	24



1.1 Généralités

Cette section pose le cadre conceptuel et théorique indispensable à notre étude. L'industrialisation d'un système intelligent ne repose pas uniquement sur la qualité de son algorithme, mais sur une méthodologie et une infrastructure capables de le soutenir à grande échelle. Cette partie s'articule autour de deux piliers technologiques fondamentaux : le **MLOps** (*Machine Learning Operations*) et le **Cloud Computing**.

1.1.1 Le MLOps (Machine Learning Operations)

1.1.1.1 Du DevOps au MLOps : Définition et nécessité

Le MLOps tire ses origines des pratiques d'ingénierie logicielle traditionnelles, particulièrement du DevOps (*Development and Operations*). Le DevOps a révolutionné la création de logiciels en fusionnant le développement et l'exploitation pour introduire l'Intégration Continue (CI) et la Livraison Continue (CD), garantissant des déploiements rapides et fiables [9].

Cependant, l'application stricte du DevOps aux systèmes d'intelligence artificielle s'est révélée insuffisante. Contrairement aux logiciels traditionnels dont le comportement est dicté par des règles de code statiques, les systèmes d'apprentissage automatique déduisent leur comportement à partir des données [9]. Le MLOps se définit donc comme une discipline d'ingénierie à l'intersection de l'apprentissage automatique, de l'ingénierie des données (*Data Engineering*) et du DevOps [9].

La différence fondamentale réside dans l'évolution du système en production. Le DevOps automatise le cycle de vie d'un seul artefact (le code), tandis que le MLOps doit gérer un cycle complexe impliquant trois artefacts interdépendants : le code, les données et le modèle [2, 9]. Lorsqu'un modèle est confronté aux données changeantes du monde réel, ses performances se dégradent inévitablement. Le MLOps introduit ainsi une nouvelle pratique : l'**Entraînement Continu** (*Continuous Training* - CT), permettant de réentraîner le modèle pour qu'il reste pertinent au fil du temps [2, 3].

1.1.1.2 Les défis de l'IA et la « dette technique cachée »

Développer un modèle prédictif performant en laboratoire est aujourd'hui rapide et peu coûteux, mais son maintien en production est complexe. Comme le soulignent Sculley *et al.* dans leurs travaux fondateurs chez Google, le code spécifique à l'apprentissage automatique ne représente qu'une infime fraction d'un système IA en exploitation [6]. L'essentiel du système est constitué d'une vaste infrastructure (souvent appelée « code de liaison » ou *glue code*) dédiée à la collecte des données, à la vérification, et à la gestion des ressources [6].

L'absence d'une architecture MLOps rigoureuse conduit à l'accumulation d'une « **dette technique cachée** » (*Hidden Technical Debt*) [6]. Les systèmes ML sont vulnérables à des défis systémiques uniques :





- **L'enchevêtrement (Principe CACE) :** Dans un modèle ML, les signaux d'entrée ne sont jamais réellement indépendants. Le principe CACE (*Changing Anything Changes Everything*) stipule que la modification d'un seul hyperparamètre, ou l'ajout d'une seule caractéristique, modifie les poids de toutes les autres et altère le comportement de tout le système [6].
- **Les dépendances de données instables :** Pour fonctionner, le modèle consomme des signaux d'entrée. Si la distribution statistique de ces données change silencieusement dans le monde réel (un phénomène appelé dérive des données ou *Data Drift*), les prédictions se dégradent sans qu'aucune erreur logicielle ne soit déclenchée [6].
- **Les boucles de rétroaction cachées :** Un modèle déployé finit souvent par influencer les futures données qu'il va ingérer (par exemple, un système de recommandation qui modifie le comportement de clic des utilisateurs), créant des boucles de rétroaction extrêmement complexes à diagnostiquer [6].

1.1.1.3 Principes fondamentaux et cycle de vie MLOps

Pour rembourser cette dette technique et automatiser le déploiement, l'architecture MLOps s'appuie sur des modèles de conception (*design patterns*) rigoureux. Selon la littérature scientifique [9] et les standards de l'industrie (CD4ML) [3], un système MLOps complet repose sur les principes suivants :

- **L'orchestration des flux de travail (Pipelines) :** Les tâches complexes (ingestion des données, ingénierie des caractéristiques, entraînement du modèle) sont coordonnées par des graphes orientés acycliques (DAG). Cette automatisation garantit que chaque étape est exécutée dans le bon ordre de manière répétable [3, 9].
- **Le versionnage unifié et la Reproductibilité :** Pour garantir une reproductibilité totale, le MLOps exige le versionnage simultané du code source (via Git), des jeux de données (*Data Versioning*) et des modèles. L'objectif est de pouvoir retracer exactement quels paramètres et quelles données ont généré une prédiction spécifique, une exigence non négociable en production [2, 9].
- **Le Registre de Modèles (*Model Registry*) :** Une fois entraîné et validé, le modèle est stocké dans un registre centralisé avec ses métadonnées et son lignage (*lineage*), prêt à être déployé [3, 9].
- **La Supervision en continu et les Boucles de rétroaction :** Le système intègre des outils d'observabilité pour surveiller la latence, la précision des prédictions et la dérive des données. Cette supervision alimente une boucle de rétroaction (*Feedback Loop*) qui déclenche automatiquement les pipelines de réentraînement (CT) dès que les performances chutent sous un seuil acceptable [3, 9].





1.1.2 Le Cloud Computing : Catalyseur de l'IA à grande échelle

1.1.2.1 Fondements et élasticité (Découplage Stockage/Calcul)

Le *Cloud Computing* (informatique en nuage) désigne la fourniture à la demande de ressources informatiques (puissance de calcul, stockage, bases de données, réseaux) via Internet, avec une tarification basée sur la consommation réelle (modèle *Pay-As-You-Go*). Dans le contexte de l'Intelligence Artificielle, l'industrie s'est massivement tournée vers le Cloud pour surmonter les limitations des infrastructures locales (*On-Premise*), qui s'avèrent souvent trop rigides et coûteuses face aux besoins exponentiels en calcul imposés par le traitement de données massives (Big Data) [1].

L'avantage architectural majeur du Cloud pour le MLOps est de permettre le découplage physique entre le stockage des données et la puissance de calcul [4]. Cette approche garantit une élasticité totale : les grappes de serveurs (clusters) peuvent être provisionnées dynamiquement lors de l'entraînement des modèles ou du prétraitement des données, puis détruites immédiatement après, optimisant ainsi l'allocation des ressources [7].

1.1.2.2 Modèles de services Cloud appliqués au MLOps

La force du Cloud Computing réside dans ses différents niveaux d'abstraction, permettant de structurer l'environnement technique selon les besoins spécifiques des équipes [1] :

- **IaaS (Infrastructure as a Service)** : Fournit les briques matérielles fondamentales virtualisées (serveurs, réseaux, disques). Pour le MLOps, l'IaaS permet aux ingénieurs de construire des architectures de calcul distribué sur-mesure, disposant de processeurs spécifiques (CPU, GPU, RAM) pour accélérer l'entraînement des réseaux de neurones complexes [1, 10].
- **PaaS (Platform as a Service)** : Offre des environnements de développement et de déploiement entièrement managés. C'est le modèle privilégié pour l'industrialisation de l'IA, car il élimine la gestion fastidieuse des serveurs sous-jacents. Il fournit des espaces de travail prêts à l'emploi (*workspaces*) et des services d'orchestration de conteneurs (ex : Kubernetes) ou de calcul distribué (ex : Apache Spark sur Amazon EMR) [1, 11].
- **SaaS (Software as a Service)** : Propose des applications logicielles complètes accessibles directement via une interface web ou une API. Dans le cadre de l'IA, cela inclut des modèles pré-entraînés prêts à être interrogés sans aucune gestion de l'infrastructure [1].

1.1.2.3 Défis sécuritaires et souveraineté des données

Malgré sa flexibilité, l'externalisation des données d'entreprise et des modèles d'IA sur des serveurs distants soulève des défis critiques en matière de sécurité, de confidentialité et de conformité réglementaire [7, 12] :





- **Souveraineté et Conformité (RGPD) :** Le Règlement Général sur la Protection des Données (RGPD) impose en Europe un cadre très strict sur la collecte et le stockage des données. Les architectes doivent s'assurer que les données sensibles sont hébergées dans des régions Cloud physiquement situées sur le territoire européen, garantissant ainsi la souveraineté numérique du système [13].
- **Isolation réseau et gestion des identités (IAM) :** L'architecture Cloud doit impérativement intégrer des mécanismes de chiffrement robustes (au repos et en transit). De plus, l'utilisation de Réseaux Privés Virtuels (VPC - *Virtual Private Cloud*) et la mise en place de politiques de gestion des identités et des accès (IAM - *Identity and Access Management*) appliquant le principe du "moindre privilège" sont indispensables pour sécuriser les environnements et empêcher toute fuite de données [8].

1.1.2.4 L'optimisation des coûts : L'approche FinOps

Le passage à l'échelle dans le Cloud introduit un risque d'explosion des coûts si les ressources ne sont pas gérées avec rigueur. Le FinOps (*Financial Operations*) est une pratique de gestion financière des ressources Cloud visant à maximiser la valeur métier. Dans le cadre du MLOps, cela se traduit par l'automatisation de la destruction des ressources inactives (clusters éphémères) et par l'exploitation d'instances de calcul à prix réduit (telles que les instances "Spot", qui exploitent la capacité excédentaire des fournisseurs Cloud) pour les charges de travail distribuées et tolérantes aux pannes [4, 7].

1.1.2.5 Fiabilité et supervision : Approche SRE (SLA, SLO, SLI)

L'industrialisation des modèles d'intelligence artificielle requiert l'adoption de pratiques d'ingénierie de la fiabilité rigoureuses (souvent inspirées du *Site Reliability Engineering* - SRE) pour éviter l'accumulation d'une « dette technique cachée » (*Hidden Technical Debt*) en production [6]. Pour garantir qu'un système MLOps répond aux exigences de fiabilité, l'industrie s'appuie sur trois concepts opérationnels fondamentaux :

- **SLA (Service Level Agreement - Accord de niveau de service) :** Il s'agit du contrat établi avec les consommateurs du modèle, définissant les attentes globales de performance (disponibilité, temps de réponse, etc.). Dans un système ML, l'établissement de SLA stricts est par exemple essentiel pour protéger le modèle contre des « consommateurs non déclarés » (*undeclared consumers*) qui pourraient le surcharger et compromettre la stabilité du système [6]. L'architecture Cloud dans son ensemble doit être alignée sur ces SLA [7].
- **SLO (Service Level Objective - Objectif de niveau de service) :** Il s'agit de l'objectif interne de performance. Les processus d'alimentation en données (en amont) et le système ML lui-même doivent être testés et supervisés en continu pour atteindre les objectifs de





niveau de service (SLO) fixés. Toute défaillance du modèle à respecter ces SLO doit être immédiatement propagée vers les systèmes dépendants en aval [6].

- **SLI (Service Level Indicator - Indicateur de niveau de service)** : C'est la métrique réelle et mesurable. Au-delà des SLI classiques de l'ingénierie logicielle (latence d'inférence, utilisation CPU/RAM), les systèmes d'IA introduisent des indicateurs très spécifiques : la dégradation de la précision algorithmique et le taux de dérive des données (*Data Drift*) [2, 7].

En production, le non-respect d'un SLO (mesuré par la chute critique d'un SLI, comme l'apparition d'une dérive de données) agit comme un déclencheur automatisé. Le pipeline MLOps doit être instrumenté pour détecter cette dégradation et ordonner l'exécution d'un cadre de réentraînement automatisé (*automated re-training framework*) avec de nouvelles données fraîchement collectées [2, 7]. À titre d'exemple pratique, une architecture MLOps robuste peut être configurée pour déclencher automatiquement un réentraînement dès lors qu'un indicateur de dérive statistique dépasse un seuil de tolérance prédéfini (ex : statistique KS > 0.20) [12].

1.1.2.6 Défis sécuritaires, conformité et protection des données

Malgré sa flexibilité, l'externalisation des données d'entreprise et des modèles d'IA sur des serveurs distants soulève des défis critiques en matière de sécurité, de confidentialité (protection des données personnelles et sensibles) et de conformité réglementaire [7]. Pour concevoir un système MLOps de qualité production, l'architecture doit impérativement intégrer des mécanismes de protection à plusieurs niveaux :

- **Souveraineté, résidence des données et conformité (ex : RGPD)** : Les cadres réglementaires (comme le RGPD en Europe) imposent des contrôles stricts sur la collecte, le traitement et le stockage des données. L'architecture doit intégrer dès sa conception la validation des permissions et de la confidentialité [7]. Pour s'y conformer, les ingénieurs doivent s'assurer que les données sensibles sont physiquement hébergées dans des régions Cloud spécifiques (ou via des solutions périphériques comme *AWS Local Zones*) afin de garantir la souveraineté numérique et de respecter les exigences strictes de résidence des données (*Data Residency*) inhérentes aux charges de travail réglementées [7].
- **Chiffrement et gestion des accès (IAM)** : Face aux législations extraterritoriales (telles que le *CLOUD Act* américain) et aux menaces de cybersécurité, l'infrastructure doit nativement intégrer des mécanismes de chiffrement robustes pour les données au repos et en transit (*Encryption at rest and in transit*) afin d'en assurer l'obfuscation [7]. De plus, la sécurisation des environnements exige la mise en place de politiques de Gestion des Identités et des Accès (IAM) appliquant rigoureusement le « principe du moindre privilège » (*Least privilege access*). Cela permet de cloisonner hermétiquement les réseaux, d'isoler les rôles d'exécution et de prévenir tout accès non autorisé aux environnements d'entraînement et d'inférence [7, 14].





1.2 État de l'art

Un véritable état de l'art exige de confronter les théories scientifiques et les modélisations conceptuelles issues de la recherche académique aux retours d'expérience concrets des leaders de l'industrie. En effet, comme le soulignent Sculley et al. dans leurs travaux de recherche fondateurs, le code algorithmique ne représente qu'une infime fraction d'un système d'apprentissage automatique en production ; le reste est constitué d'une vaste infrastructure complexe de collecte, de vérification des données, de configuration et de supervision active [6]. L'absence d'une architecture globale et standardisée conduit inévitablement à l'accumulation d'une « dette technique cachée » [6], entravant l'innovation opérationnelle et la robustesse des systèmes d'intelligence artificielle.

C'est pour surmonter ces verrous d'ingénierie que le paradigme du MLOps (*Machine Learning Operations*) s'est imposé à l'intersection du génie logiciel (DevOps), de l'ingénierie des données (*Data Engineering*) et de l'apprentissage automatique [9]. Néanmoins, concevoir un système MLOps hautement scalable et économiquement viable nécessite une double analyse : d'une part, l'étude des modèles de maturité, de découplage et de surveillance théorisés par la communauté scientifique, et d'autre part, la déconstruction des patrons d'architecture (*design patterns*) éprouvés sur le terrain par les géants du secteur technologique.

Cette section propose ainsi une exploration structurée en deux temps :

- Une **revue de la littérature scientifique** analysant les concepts de gouvernance, de modularité (DataOps vs ModelOps), d'automatisation des infrastructures (IaC), et de supervision de la dérive statistique (*drift*) à travers huit contributions académiques récentes.
- Un panorama de **cinq retours d'expérience industriels** (Netflix, Capital One, Riot Games, Expedia Group, et un modèle de référence basé sur l'Infrastructure as Code) afin de justifier techniquement l'architecture hybride retenue pour le compte de notre organisation.

1.2.1 Revue de la littérature scientifique (Approche académique)

L'étude de la littérature scientifique récente permet d'identifier quatre piliers fondamentaux structurant la recherche contemporaine en ingénierie des systèmes d'apprentissage automatique.

1.2.1.1 Gouvernance et maturité des cycles de vie MLOps

La transition d'un modèle expérimental local vers un environnement de production requiert l'adoption d'un cycle de vie standardisé. Hanchuk et Semerikov proposent une méta-synthèse exhaustive des pratiques d'ingénierie du Machine Learning, soulignant que la réussite du déploiement à l'échelle industrielle dépend de la mise en place d'un workflow reproductible allant de l'ingestion brute jusqu'à l'observabilité continue [15]. Cette transition exige une redéfinition des





rôles professionnels, nécessitant une collaboration étroite entre les Data Scientists, les ingénieurs de données et les experts DevOps.

Ce besoin de standardisation est approfondi par Reddy, qui conceptualise la livraison continue appliquée au Machine Learning (CD4ML) [16]. L'auteur démontre que l'architecture MLOps doit gérer simultanément la triple dualité et le versionnage synchrone de trois artefacts hautement dynamiques : le code applicatif, les données massives et les paramètres algorithmiques du modèle [16].

1.2.1.2 Découplage architectural et modularité (DataOps vs ModelOps)

Face à la complexité des systèmes d'intelligence artificielle, la modularité s'impose comme une exigence de conception majeure. Mutya et Majety forment un framework d'ingénierie adaptatif et robuste qui sépare physiquement la couche d'ingénierie des données (*DataOps*), responsable de la validation et des pipelines de features, de la couche de modélisation (*ModelOps*), dédiée à l'apprentissage et au déploiement [17]. Ce découplage fonctionnel permet de réduire le temps de mise en production de 40 % et d'éviter les goulots d'étranglement de traitement.

Pour opérationnaliser cette modularité sur les infrastructures modernes, Jana propose un plan technique d'automatisation des pipelines MLOps sur le Cloud, détaillant la pertinence d'un découplage complet entre le stockage d'un lac de données (Data Lake) et les services éphémères de calcul parallèle pour l'entraînement et l'inférence [18].

1.2.1.3 Automatisation par le code (IaC) et orchestration Cloud

L'un des verrous traditionnels de l'industrialisation de l'IA réside dans la configuration manuelle et instable des infrastructures de calcul. Les travaux empiriques de Behl et al. démontrent que l'automatisation complète de l'environnement de calcul via l'intégration et le déploiement continus (CI/CD) réduit les délais opérationnels de 65 % et augmente significativement la résilience opérationnelle du système [19].

Pour sélectionner les outils supports de cette automatisation, Moreschini et al. dressent une étude comparative rigoureuse des plateformes de MLOps des grands fournisseurs de Cloud (AWS, Azure, GCP et Databricks) [20]. Les auteurs évaluent ces solutions selon cinq dimensions critiques : la performance, les coûts, l'ouverture, la gestion de données et la courbe d'apprentissage. L'étude met notamment en valeur la robustesse d'Amazon Web Services, dont l'écosystème s'articule de façon optimale autour d'une approche de stockage centralisée et sécurisée (Amazon S3) [20].

1.2.1.4 Observabilité, dérive (Drift) et réentraînement continu (CT)

Le cycle de vie d'un modèle ne s'arrête pas à sa mise en production ; il est soumis au phénomène silencieux de dégradation des performances algorithmiques (*model decay*). Nogare et





al. développent une méthodologie d'observabilité active pour capter dynamiquement la dérive des données (*data drift*) et la dérive de concept (*concept drift*) en environnement de production [21]. Validée à grande échelle au sein de l'institution financière Itaú Unibanco, cette approche systématique a permis de ramener le délai de déploiement des nouveaux modèles de six mois à seulement quelques jours, tout en garantissant une transparence opérationnelle totale [21].

Enfin, l'implémentation concrète de cette boucle fermée d'entraînement continu (Continuous Training) est illustrée par Águila Cifuentes à travers un cadre d'expérimentation applicatif montrant comment un orchestrateur de tâches et des interfaces de visualisation permettent de déclencher automatiquement le réentraînement dès la détection d'une déviation statistique des données de production [22].

1.2.2 Retours d'expérience et architectures industrielles (Cas d'étude)

Bien que la recherche académique pose les jalons conceptuels de la standardisation des flux, l'évaluation des architectures mises en œuvre par les leaders de l'industrie technologique s'avère indispensable pour appréhender les contraintes réelles de charge, de latence et de disponibilité. Les sous-sections suivantes analysent les choix de conception de cinq architectures de référence en production.

1.2.2.1 Cas d'étude 1 : Netflix – Architecture MLOps de référence, orchestration hybride et passage à l'échelle

1. Contexte et ampleur du défi technique

Netflix s'appuie sur le Cloud AWS pour diffuser des milliards d'heures de contenu à l'échelle mondiale et opérer sa plateforme analytique [23]. La création de modèles d'intelligence artificielle personnalisés exige d'entraîner un modèle spécifique pour chaque pays et chaque langue, ce qui génère une base de 2 000 à 4 000 modèles en production [4]. Lors des phases de recherche d'hyperparamètres (*hyperparameter sweeps*), ce volume explose pour atteindre simultanément entre 10^5 et 10^6 modèles [4]. Ces charges de travail massives, imprévisibles et extrêmement gourmandes en ressources (processeurs, mémoire, GPU) risquent à tout moment de saturer l'infrastructure et d'impacter les applications critiques en production [4].

Pour répondre à ce défi tout en préservant la productivité des *Data Scientists*, Netflix a conçu une architecture de référence modulaire, décomposée en plusieurs couches spécialisées et documentée dans ses retours d'expérience sur AWS [4].

2. Les couches de l'architecture de référence Netflix

A. Couche de gestion des données (Data Lake et Analytics)

La fondation de l'architecture repose sur un découplage strict entre la puissance de calcul et le stockage :





- **Data Lake unique** : L'intégralité des données (pétaoctets de vidéos et données tabulaires) est centralisée sur Amazon S3 [4].
- **Formats et Moteurs de requêtes** : Les données tabulaires sont stockées au format Parquet et exposées via des tables Iceberg [4]. Pour interroger ces données, Netflix utilise des moteurs de calcul distribué comme Apache Spark et Presto [4].
- **Fédération et Métadonnées** : L'accès est abstrait par *Genie*, un moteur de requêtes fédéré développé en interne (open source), tandis que la découverte des données et la gestion des métadonnées sont assurées par *Metacat* [4].
- **Bypass pour le ML** : Pour éviter les goulots d'étranglement des moteurs SQL lors de l'entraînement, des outils spécifiques permettent aux pipelines ML de se connecter directement à S3, saturant la bande passante réseau pour ingérer les données à très haute vitesse [4].

B. Couche d'orchestration des conteneurs et de calcul (Compute)

- **Conteneurisation via Titus / AWS Batch** : Netflix utilise son orchestrateur interne *Titus* (dont l'équivalent AWS est AWS Batch) pour lancer des conteneurs à grande échelle depuis les environnements locaux vers le Cloud [4].
- **Mécanisme de files d'attente (Isolation)** : Pour éviter que les pics d'entraînement n'impactent la production, les requêtes ML sont placées dans des files d'attente strictes. Ces files "fuient" (*leak*) progressivement les tâches vers Amazon ECS ou Kubernetes en fonction des priorités [4].
- **Optimisation FinOps par l'IA** : Les instances GPU étant onéreuses, Netflix a développé des modèles de Machine Learning secondaires chargés de prédire avec précision les ressources (CPU, RAM, GPU) requises par une tâche avant son lancement [4]. Cela permet un placement optimal des *jobs* sur les serveurs physiques, augmentant le taux d'utilisation et réduisant drastiquement les coûts opérationnels [4].

C. Couche d'orchestration des Workflows (Pipelines)

Les pipelines ML de Netflix peuvent durer des semaines (par exemple pour la vision par ordinateur) et nécessitent de transférer le calcul d'une instance à forte mémoire vers une instance GPU [4].

- **Netflix Conductor / AWS Step Functions** : L'orchestration asynchrone des différentes étapes du pipeline est gérée par *Netflix Conductor* (équivalent d'AWS Step Functions). Il gère la montée en charge requise pour exécuter des milliers de tests A/B en parallèle [4].
- **Signalisation des données (Data Signaling)** : L'architecture est purement événementielle. Au lieu d'interroger les bases de données à intervalles réguliers (*polling*), les pipelines ML sont déclenchés automatiquement par des événements (via Amazon EventBridge) dès qu'un pipeline ETL en amont a terminé l'écriture d'une table [4].





D. Couche d'environnement de développement et d'observabilité

- **Workspaces interactifs** : Les *Jupyter Notebooks* (Python, R) sont hébergés sur des instances Amazon SageMaker Notebooks [4]. Pour l'écosystème Scala/JVM, Netflix a développé et rendu open source le projet *Polynote* [4].
- **Supervision as Code** : La surveillance des modèles en production (temps d'exécution, comportement du flux) est réalisée via des notebooks transformés en tableaux de bord. Grâce aux outils open source *Papermill* et *Commuter*, les notebooks sont exécutés périodiquement et hébergés pour fournir des visualisations interactives via des bibliothèques comme Bokeh ou Plotly [4].

3. Le Framework Fédérateur : Metaflow

Pour lier toutes ces couches d'infrastructure sans forcer les *Data Scientists* à devenir des experts en ingénierie Cloud (Docker, Step Functions), Netflix a créé **Metaflow** [4]. Ce framework Python abstrait la complexité :

- L'utilisateur écrit du code Python idiomatique (TensorFlow, PyTorch, Scikit-learn) [4].
- Metaflow intègre une couche de données à haut débit depuis Amazon S3 [4].
- L'ajout d'un simple décorateur (ex : @batch) dans le code suffit pour que la fonction soit automatiquement exécutée sur une instance AWS Batch avec une mémoire ou des GPU spécifiés [4].
- En un clic, le code Python est compilé et exporté vers AWS Step Functions pour une orchestration en production [4].
- Metaflow versionne automatiquement toutes les métadonnées de chaque exécution, garantissant une reproductibilité totale [4].

4. Implémentation de référence sur AWS (Infrastructure as Code)

L'architecture de Netflix est reproductible via un modèle AWS CloudFormation (disponible via `netflix/metaflow-tools`) qui provisionne l'infrastructure complète [4].

- **Ressources provisionnées** : L'infrastructure déploie automatiquement un bucket S3 pour les artefacts, un environnement de calcul AWS Batch (avec mode de provisionnement EC2), un cluster Amazon ECS Fargate (avec accès au port 80), une base de données Postgres, DynamoDB, et un Network Load Balancer (NLB) [4].
- **Sécurité IAM stricte** : Des rôles AWS IAM appliquant le principe du moindre privilège sont générés pour garantir que, par exemple, AWS Batch ne puisse extraire de S3 que les données strictement nécessaires, de manière sécurisée [4].
- **Intégration et Catalogue** : L'ensemble est intégré à Amazon EventBridge pour la signalisation des données et à AWS Service Catalog pour mettre cette infrastructure à disposition des utilisateurs via un portail en libre-service [4].





Tableau Synthétique : Correspondance des composants (Netflix vs AWS)

TABLEAU 1.1 – Cartographie de l'Architecture de Référence MLOps (Netflix vs AWS)

Couche Architecturale	Outil Interne / Open Source Netflix	Équivalent / Service Managé AWS
Stockage (Data Lake)	S3, Iceberg, Parquet [4]	Amazon S3 [4]
Requêtage & Métadonnées	Genie, Metacat, Presto, Spark [4]	Amazon Athena, AWS Glue, EMR
Calcul & Conteneurisation	Titus [4]	AWS Batch, Amazon ECS (Fargate) [4]
Orchestration de Workflows	Netflix Conductor [4]	AWS Step Functions [4]
Signalisation (Événements)	Bus d'événements interne [4]	Amazon EventBridge [4]
Environnement (Workspace)	Polynote, Jupyter [4]	Amazon SageMaker Notebooks [4]
Supervision (Dashboards)	Papermill, Commuter [4]	Amazon CloudWatch
Framework d'abstraction	Metaflow [4]	Amazon SageMaker Pipelines

1.2.2.2 Cas d'étude 2 : Capital One – MLOps ultra-sécurisé, conformité et gouvernance dans le secteur bancaire (FSI)

1. Contexte et exigences du secteur financier

Le secteur des services financiers (Financial Services Industry - FSI) est soumis à des contraintes réglementaires extrêmes. Pour Capital One, une banque gérant plus de 100 millions de clients, l'adoption de l'Intelligence Artificielle générative ne pouvait se faire sans une infrastructure capable de prouver aux régulateurs que chaque décision est auditable, sécurisée et maîtrisée [24]. L'enjeu technique était de passer à l'échelle pour des dizaines de milliers d'employés (notamment plus de 10 000 agents du service client utilisant déjà l'IA générative dans leur flux de travail), tout en atténuant de manière stricte les risques de non-conformité [24].

2. Fondation architecturale : Migration "All-In" et Cloud-Native

Pour rendre possible une pratique MLOps performante et réactive, Capital One a pris une décision d'infrastructure radicale : fermer la totalité de ses centres de données physiques (passant d'environ 15 centres à zéro) pour migrer à 100 % vers le Cloud public AWS [24].

- **Centralisation sur Amazon S3 et "Data Gravity"** : Cette migration a permis de consolider l'intégralité des données propriétaires sur Amazon S3 [24]. Ce choix architectural a rapproché physiquement les données des grappes de calcul surpuissantes, créant un effet





de « gravité des données » (*Data Gravity*) considéré par les architectes de la banque comme le précurseur indispensable au succès de l'IA [24].

- **Architecture Serverless** : Le développement MLOps de Capital One s'inscrit dans une démarche *Cloud-native* et *Serverless*, éliminant la gestion des serveurs sous-jacents pour les scientifiques des données et offrant une élasticité instantanée [24].

3. La Gouvernance MLOps : Le modèle des « Trois Lignes de Défense »

Contrairement aux entreprises technologiques classiques, l'architecture MLOps d'une banque doit intégrer la conformité de manière systémique. Capital One a institutionnalisé un modèle de gouvernance strict à "trois lignes de défense" [24] :

- **1^{ère} Ligne (Développeurs et MLOps)** : Les ingénieurs et chercheurs conçoivent les solutions, en intégrant des pratiques de responsabilité algorithmique dès la conception (*Privacy by design*) [24].
- **2^{ème} Ligne (Bureau des Risques / *Model Risk Office*)** : Cette équipe indépendante de la première ligne évalue, conteste et valide chaque modèle avant son déploiement. Des tests de référence internes et externes rigoureux sont exécutés pour s'assurer que le modèle respecte les normes de l'entreprise et la loi [24].
- **3^{ème} Ligne (Audit interne et externe)** : Une fonction d'audit inspecte le système en continu et fait un rapport direct au conseil d'administration. Les régulateurs gouvernementaux interviennent au minimum chaque trimestre pour vérifier que les contrôles entre la première et la deuxième ligne sont effectifs [24].

4. Couche de Sécurité Active : L'intégration des "Guardrails"

Pour déployer des modèles génératifs sans risquer d'exposer des données ou de subir des attaques, l'architecture MLOps intègre nativement des garde-fous, notamment *NeMo Guardrails* (développé par NVIDIA), au cœur de son pipeline d'inférence [24].

- **Sécurisation en Entrée** : Les garde-fous interceptent et bloquent les requêtes malveillantes (tentatives de *Jailbreak* ou d'injection de requêtes) de manière dynamique, en exploitant les bases de données de menaces mondiales mises à jour en continu [24].
- **Sécurisation en Sortie et Human-in-the-Loop** : Les réponses sont filtrées en temps réel pour garantir que le modèle reste sur le sujet autorisé et que le contenu généré est sûr. Pour les cas d'usage à haut risque impliquant des clients finaux, un agent humain valide les sorties avant toute transmission (*Human-in-the-Loop*) [24].

5. Qualité des données, Personnalisation (Fine-Tuning) et FinOps

Les architectes de Capital One ont constaté que les modèles généralistes prêts à l'emploi n'offraient pas la précision requise pour les spécificités de la culture d'entreprise bancaire [24].





- **Qualité vs Volume** : L'architecture insiste sur la qualité des données (complétude, nettoyage, cohérence) plutôt que sur le simple volume. Des pipelines automatisés assurent la qualité des données d'entraînement, étape cruciale pour éviter que les modèles ne se basent sur des variations aberrantes [24].
- **PEFT et LoRA** : La plateforme MLOps intègre des pipelines de personnalisation avancés : pré-entraînement continu, ajustement fin supervisé (SFT), et des méthodes paramétriques efficaces comme LoRA (*Low-Rank Adaptation*) et QLoRA [24].
- **Optimisation FinOps massive de l'inférence** : L'inférence représentant le coût continu le plus élevé, l'infrastructure est rigoureusement optimisée. Cette ingénierie de pointe a permis à Capital One de réduire les coûts d'inférence de trois ordres de grandeur (un facteur 1 000) en l'espace de seulement 20 mois [24].

6. Supervision Post-Déploiement et Effet "Heisenberg"

Chez Capital One, le déploiement d'un modèle n'est considéré que comme « la première marche de l'escalier vers le paradis de l'IA » [24].

- **L'effet Heisenberg et la dérive induite** : L'entreprise observe que le simple fait de déployer un modèle modifie le comportement des utilisateurs, ce qui altère rapidement la distribution des données réelles par rapport à la phase d'entraînement. Le pipeline MLOps gère donc une observabilité continue pour capturer cette nouvelle réalité et déclencher des réentraînements [24].
- **Validation en ligne (A/B Testing)** : Parce que les tests hors ligne sur des données anciennes ne sont souvent pas de bons prédicteurs des performances réelles, la plateforme MLOps est instrumentée pour exécuter des tests en ligne limités (A/B testing) afin de valider continuellement la performance des algorithmes en production [24].

Tableau Synthétique : Correspondance des composants (Capital One)





TABLEAU 1.2 – Cartographie de l'Architecture MLOps Sécurisée (Secteur Bancaire / FSI)

Exigence / Couche Architecturale	Solutions et Pratiques implémentées
Stockage (Data Gravity)	Migration totale sur AWS, stockage massif et centralisé sur Amazon S3 [24]
Sécurisation (Entrée/Sortie)	Déploiement de <i>NVIDIA NeMo Guardrails</i> pour filtrer le <i>Jail-break</i> et garantir la sécurité du contenu (avec <i>Human-in-the-Loop</i> si nécessaire) [24]
Gouvernance (Conformité)	Validation stricte à 3 lignes de défense : 1. Développeurs, 2. Model Risk Office, 3. Auditeurs et Régulateurs [24]
Ajustement des modèles	Personnalisation via <i>Fine-Tuning</i> , LoRA et QLoRA [24]
Supervision	Observabilité continue pour contrer la dérive des données (Effet Heisenberg) et Tests A/B en production [24]

1.2.2.3 Cas d'étude 3 : Riot Games – Inférence et déploiement mondialisé à très faible latence (Edge Computing)

1. Contexte et exigence de latence critique

Pour des jeux compétitifs d'envergure mondiale tels que *League of Legends*, l'expérience du joueur et la réactivité de l'infrastructure sont des piliers fondamentaux. Face à l'augmentation de la base de joueurs, Riot Games a identifié l'opportunité de moderniser son infrastructure tout en maintenant une empreinte mondiale [10]. Le défi d'ingénierie consistait à déployer des serveurs de jeu et des charges de travail applicatives capables de s'adapter dynamiquement à l'activité des joueurs, tout en éliminant les délais de transmission inhérents aux architectures Cloud trop centralisées [10].

2. La stratégie de déploiement hybride et standardisée

Pour contourner les limites physiques de la latence, Riot Games a repensé la topologie de son infrastructure en adoptant un modèle de déploiement mondial standardisé à trois niveaux d'abstraction [10] :

- **Niveau 1 (Régions AWS)** : L'infrastructure privilégie en premier lieu les *Régions AWS* classiques lorsqu'elles sont disponibles et suffisamment proches des bassins de joueurs [10].
- **Niveau 2 (AWS Local Zones)** : Lorsque les Régions sont trop éloignées, Riot Games s'appuie sur les *AWS Local Zones*. Celles-ci rapprochent les services fondamentaux d'AWS (calcul, stockage) directement dans les grandes zones métropolitaines du monde entier, offrant la même élasticité à la demande mais avec une latence considérablement réduite [10].





- **Niveau 3 (AWS Outposts) :** Dans les zones géographiques où ni les Régions ni les Local Zones ne sont (encore) implantées, l'entreprise déploie *AWS Outposts* (des baies de serveurs physiques AWS installées dans des centres de données locaux) [10].

Au fur et à mesure que de nouvelles *Local Zones* sont inaugurées dans le monde, Riot Games y migre progressivement ses charges de travail depuis *Outposts*, évoluant vers un modèle où AWS gère entièrement à la fois l'infrastructure et les installations physiques [10].

3. Conteneurisation et standardisation des calculs

L'agilité de ce déploiement massif repose sur la conteneurisation. Riot Games utilise de manière intensive **Amazon EKS (Elastic Kubernetes Service)**, un service entièrement managé qui permet d'automatiser et d'exécuter des clusters Kubernetes de manière transparente dans le Cloud [10]. Ces clusters tournent sur des instances **Amazon EC2**, offrant à Riot Games une plateforme de calcul disposant du choix le plus large en matière de processeurs, de stockage et de mise en réseau pour adapter la puissance à chaque charge de travail [10].

4. Réseau dédié et contournement d'Internet

Déployer des serveurs en périphérie (*Edge*) ne suffit pas si les données doivent transiter par les routes imprévisibles de l'Internet public. Pour connecter ces déploiements distribués de manière sécurisée et ultra-rapide à son propre réseau principal (le backbone *Riot Direct*), Riot Games utilise **AWS Direct Connect** [10]. Ce service fournit une connexion réseau physique et dédiée directement reliée à l'infrastructure d'AWS, garantissant une bande passante constante et une latence minimale [10].

5. Abstraction de l'infrastructure et collaboration DevOps

L'un des bénéfices majeurs de cette architecture de référence est la transparence opérationnelle qu'elle offre aux développeurs. Comme l'indique David Press, responsable technique pour *League of Legends* : « *En tant qu'équipe de jeu, nous n'avons pas à nous demander si notre jeu tourne dans une AWS Local Zone, un AWS Outpost ou une Région AWS — c'est exactement la même chose pour nous* » [10].

Cette standardisation fournit une interface, une facturation et des outils totalement uniformisés. Elle libère les développeurs de la gestion de l'infrastructure, leur permettant d'investir leur temps dans l'amélioration de l'expérience joueur [10]. De plus, cette approche est soutenue par une collaboration étroite (planification des capacités, coordination des lancements) avec les architectes de solutions et les gestionnaires de comptes techniques d'AWS, agissant comme de véritables collaborateurs intégrés à l'équipe [10].

Tableau Synthétique : Composants de l'Architecture Mondiale (Riot Games)





TABLEAU 1.3 – Cartographie de l'Architecture Cloud à très faible latence (Riot Games / AWS)

Exigence / Couche Architecturale	Solutions et Services AWS implémentés
Déploiement en périphérie (Edge)	Stratégie combinée priorisant les Régions AWS, puis les <i>AWS Local Zones</i> (pour les métropoles mondiales), et enfin <i>AWS Outposts</i> [10]
Orchestration & Conteneurisation	Utilisation centralisée d' <i>Amazon EKS</i> (Kubernetes managé) tournant sur des instances de calcul <i>Amazon EC2</i> [10]
Interconnexion & Réseau Backbone	Connexion dédiée du réseau propriétaire (<i>Riot Direct</i>) à l'infrastructure via <i>AWS Direct Connect</i> [10]
Abstraction & Agilité	Interface et outils unifiés quel que soit le lieu d'exécution physique (Region, Local Zone ou Outpost), déchargeant les développeurs de la gestion matérielle [10]

1.2.2.4 Cas d'étude 4 : Expedia Group – Standardisation MLOps, conteneurisation et inférence multi-région

1. Contexte, fragmentation et défi de la latence globale

Le géant du voyage Expedia Group opère plus de 20 marques mondiales (Expedia, Hotels.com, Vrbo, etc.) et s'appuie sur plus de 650 équipes d'ingénierie pour soutenir 200 sites de voyage à travers le monde [13]. L'entreprise a été confrontée à un défi critique sur son service de suggestion (ESS – *Expedia Suggest Service*), un algorithme basé sur la localisation et l'historique d'achat des clients qui affiche des prédictions dès que l'utilisateur commence à taper sa recherche [25].

Cependant, l'infrastructure historique du groupe était centralisée dans un centre de données unique situé à Chandler, en Arizona. Cet éloignement physique générait une latence réseau inacceptable de 700 millisecondes pour les clients de la région Asie-Pacifique, entraînant des erreurs de page et l'abandon des utilisateurs [25]. L'enjeu était de moderniser l'infrastructure pour standardiser les déploiements de ces centaines d'équipes et rapprocher les modèles d'IA au plus près des utilisateurs finaux [13, 25].

2. Standardisation des déploiements via AWS Service Catalog

Pour unifier les pratiques d'ingénierie sans freiner l'innovation de ses 650 équipes, Expedia a mis en place une plateforme standardisée :

- **Plateforme DBaaS et Gouvernance** : L'entreprise a développé *Cerebro*, une plateforme de base de données en tant que service (DBaaS). Grâce à **AWS Service Catalog**, une petite équipe d'ingénieurs centraux a pu déployer ce catalogue à l'échelle de l'organisation, permettant aux équipes de provisionner rapidement des environnements tout en respectant nativement les meilleures pratiques et la gouvernance du groupe [13].





- **Modèle de déploiement standardisé** : En créant des modèles d'infrastructure reproductibles, les équipes de science des données ne sont plus limitées par des contraintes de débit ou de capacité CPU, et peuvent provisionner l'infrastructure de nouvelles initiatives de manière autonome [25].

3. Architecture de données massives et Conteneurisation

Pour alimenter ses modèles d'intelligence artificielle, l'architecture a été migrée vers un modèle orienté conteneurs et services managés :

- **Ingestion et orchestration Big Data** : Expedia a construit un système flexible pour ingérer de hauts volumes de données (en temps réel et par lots) en orchestrant **AWS Glue**, **Amazon DynamoDB**, **Amazon Aurora** et **Amazon CloudWatch** [13].
- **Conteneurisation via Amazon ECS** : La migration des applications vers des plateformes conteneurisées basées sur **Amazon Elastic Container Service (ECS)** a permis au groupe de se libérer de la gestion des serveurs sur site, de ne payer que pour les ressources réellement utilisées, et d'ajouter de la capacité dynamiquement [13, 25].
- **Calcul intensif (Deep Learning)** : Pour l'entraînement de ses algorithmes de traitement d'images, le groupe utilise des instances **Amazon EC2 P3** (optimisées GPU). Ces modèles analysent des dizaines de millions de photos avec une précision supérieure à 99 %, afin de sélectionner automatiquement les images d'hôtels les plus pertinentes [13].

4. Réplication Multi-Région et réduction drastique de la latence

Pour résoudre le défi de la latence de son service de suggestion (ESS), Expedia a repensé son modèle de déploiement mondial :

- **Déploiement mondial et Haute Disponibilité** : Le service a d'abord été déployé en Asie-Pacifique, puis rapidement répliqué dans les régions États-Unis et Europe. L'architecture s'appuie sur plusieurs *Zones de Disponibilité (AZ)* pour garantir la reprise après sinistre et une disponibilité continue [25]. Les données elles-mêmes sont sécurisées via **Amazon S3** et ses mécanismes de réplication automatique [13].
- **Gains de performance (Inférence)** : Le rapprochement des points d'inférence au plus près des utilisateurs a permis de faire chuter la latence moyenne du réseau de 700 millisecondes à **moins de 50 millisecondes** [25]. À l'échelle globale, cette plateforme traite plus de **600 milliards de prédictions IA par an** à partir de 70 pétaoctets de données, avec des temps de réponse sous la milliseconde [13].

5. Sécurisation et gouvernance des données personnelles (PII)

L'industrie du voyage traitant quotidiennement des données hautement sensibles, la sécurité du Data Lake est une priorité absolue :

- **Protection via Amazon Macie** : Face à l'augmentation des exigences réglementaires autour des données personnelles (PII) et de santé (PHI), Expedia applique une approche de



sécurité multicouche. Le groupe exploite **Amazon Macie**, un service qui utilise lui-même le Machine Learning pour découvrir, surveiller et protéger automatiquement les données sensibles stockées dans les environnements AWS [13].

Tableau Synthétique : Composants MLOps et Data (Expedia Group)

TABLEAU 1.4 – Cartographie de l'Architecture et des Services Cloud (Expedia Group)

Exigence / Couche Architecturale	Solutions et Services AWS implémentés
Standardisation & Libre-service	Mise à disposition d'environnements (ex : DBaaS <i>Cerebro</i>) validés et standardisés via <i>AWS Service Catalog</i> [13]
Ingestion de données	Pipelines Big Data temps réel et batch via <i>AWS Glue</i> , <i>DynamoDB</i> et <i>Amazon Aurora</i> [13]
Orchestration & Conteneurisation	Migration vers des applications conteneurisées et pilotées par <i>Amazon ECS</i> [13, 25]
Performance & Faible Latence	Réplication mondiale sur de multiples <i>Availability Zones</i> faisant chuter la latence de 700 ms à < 50 ms [25]
Gouvernance & Sécurité des PII	Détection et supervision en continu des données sensibles (PII/PHI) par <i>Amazon Macie</i> [13]

1.2.2.5 Cas d'étude 5 : Plateforme MLOps sécurisée basée sur Terraform, GitHub et Amazon SageMaker

1. Contexte et exigence d'une architecture multi-comptes

Pour industrialiser des cas d'usage d'apprentissage automatique de manière sécurisée et reproductible, les entreprises doivent s'appuyer sur des plateformes MLOps garantissant la séparation des environnements (Développement, Préproduction, Production) et l'observabilité de bout en bout [8]. Bien qu'Amazon SageMaker propose des outils CI/CD natifs, de nombreuses organisations exigent d'utiliser leurs propres standards de gestion de code et d'infrastructure pour éviter la fragmentation technologique [26]. Ce cas d'étude publié par AWS détaille une architecture de référence déployant une plateforme MLOps sécurisée reposant intégralement sur l'Infrastructure as Code (Terraform) et l'automatisation via GitHub Actions [8].

2. Fondation : Infrastructure as Code (IaC) via Terraform

L'ensemble de l'infrastructure Cloud sous-jacente est codée, versionnée et provisionnée à l'aide de Terraform, garantissant que les environnements de développement et de production sont strictement identiques [8]. L'architecture s'appuie sur sept modules Terraform réutilisables et hautement sécurisés [8] :





- **Networking (Réseau et VPC) :** Création d'un *Virtual Private Cloud* (VPC) isolé, comprenant des sous-réseaux privés, des groupes de sécurité, des passerelles NAT et de multiples *VPC Endpoints*. Cela permet à SageMaker de communiquer avec les autres services AWS de manière sécurisée sans transiter par l'Internet public [8].
- **Sécurité (IAM et KMS) :** Déploiement de clés de chiffrement gérées par le client via *AWS Key Management Service* (KMS) pour chiffrer les données. Des rôles *AWS IAM* basés sur le principe du moindre privilège sont générés spécifiquement pour les utilisateurs et les services SageMaker [8].
- **Gestion de l'état (S3) :** Conformément aux bonnes pratiques de l'IaC, l'état de l'infrastructure Terraform est verrouillé et stocké de manière centralisée sur Amazon S3 [8].

3. Intégration CI/CD : GitHub, GitHub Actions et AWS CodeStar

Le code source des modèles et la configuration de l'infrastructure sont hébergés sur **GitHub**. L'automatisation du cycle de vie est assurée par **GitHub Actions**, qui orchestre la construction, les tests et le déploiement de manière agnostique [8, 26].

- **AWS CodeStar Connection :** Pour permettre à AWS de communiquer de manière sécurisée avec le dépôt GitHub, une connexion *AWS CodeStar* est établie. Le jeton d'accès personnel (PAT) de GitHub est stocké de manière chiffrée dans *AWS Secrets Manager* [26].
- **Validation manuelle (GitHub Environments) :** Pour le déploiement des modèles vers les comptes de Préproduction et de Production, l'architecture utilise la fonctionnalité *Environments* de GitHub, qui impose l'approbation manuelle d'un réviseur désigné avant d'autoriser la mise en production [26].

4. Modèles de déploiement en libre-service (SageMaker Projects & Service Catalog)

Afin d'offrir une expérience en libre-service aux *Data Scientists* sans compromettre la sécurité, l'architecture utilise **Amazon SageMaker Projects** couplé à **AWS Service Catalog** [8, 26].

- **Portefeuille de modèles personnalisés :** Les ingénieurs MLOps créent un portefeuille de modèles CloudFormation personnalisés dans Service Catalog (ex : modèle d'entraînement pour LLM, modèle de déploiement BYOC - *Bring Your Own Container*) [8].
- **Clonage automatisé via Lambda :** Lorsqu'un utilisateur initie un nouveau projet dans SageMaker Studio, une fonction *AWS Lambda* est automatiquement invoquée pour cloner un dépôt GitHub privé contenant le code de base du modèle sélectionné, préparant ainsi l'espace de travail instantanément [8].

5. Orchestration du Workflow et Registre de modèles (SageMaker Pipelines)

Une fois le code poussé sur GitHub, GitHub Actions déclenche l'exécution d'**Amazon SageMaker Pipelines**. Ce service orchestre les flux de travail d'apprentissage automatique de manière native sur AWS [8, 26] :





- **Exécution du pipeline (DAG) :** Le graphe d'exécution gère la préparation des données, l'entraînement du modèle et son évaluation de manière automatisée [26].
- **SageMaker Model Registry :** Si le modèle dépasse le seuil de précision requis, il est automatiquement enregistré dans le registre de modèles centralisé (*Model Registry*) d'AWS avec son lignage de données complet et ses métriques [8, 26].
- **Déclenchement événementiel (EventBridge) :** *Amazon EventBridge* surveille le registre. Lorsque le statut d'un modèle passe à "Approuvé", *EventBridge* déclenche une fonction *Lambda* qui lance à son tour le workflow de déploiement dans *GitHub Actions* pour créer les *Endpoints* de staging ou de production [26].

Tableau Synthétique : Composants MLOps (Terraform, GitHub, SageMaker)

TABLEAU 1.5 – Cartographie de l'Architecture de Référence (AWS, Terraform, GitHub)

Couche / Exigence Technique	Solutions et Services implémentés
Infrastructure as Code (IaC)	Provisionnement du réseau (VPC, Endpoints), de la sécurité (IAM, KMS) et du stockage codé via <i>Terraform</i> [8]
Intégration & Déploiement (CI/CD)	Orchestration complète via <i>GitHub Actions</i> avec approbation manuelle (<i>Environments</i>) [8, 26]
Gouvernance & Libre-service	Mise à disposition des templates projets via <i>AWS Service Catalog</i> connectés à <i>GitHub</i> via <i>AWS Lambda</i> et <i>CodeStar</i> [8, 26]
Orchestration des Workflows	Apprentissage automatisé via <i>Amazon SageMaker Pipelines</i> (graphe DAG) [8, 26]
Registre & Automatisation	Versionnage dans <i>SageMaker Model Registry</i> . Le passage en production est détecté par <i>Amazon EventBridge</i> [26]

1.2.3 Bilan de l'état de l'art et Positionnement technologique du projet

1. Bilan de l'état de l'art

L'analyse croisée de la littérature scientifique récente [15, 16, 17, 18, 19, 20, 21, 22] et des architectures industrielles de référence (Netflix, Capital One, Riot Games, Expedia) met en évidence une convergence absolue sur trois principes directeurs fondamentaux :

1. **Le découplage physique strict** entre la brique d'ingénierie des données massives (*DataOps*) et l'environnement d'apprentissage et d'inférence (*ModelOps*) pour éliminer les verrous de saturation mémoire et garantir la scalabilité [17, 18].
2. **L'automatisation intégrale par le code (IaC)** et le déploiement continu (CI/CD) pour éliminer les dérives de configuration, réduire les délais de livraison et fiabiliser les environnements Cloud complexes [19, 20].





3. **L'observabilité active et le réentraînement continu (CT)** pour contrer la dégradation silencieuse des performances algorithmiques causée par la dérive statistique des données réelles [21, 22].

2. Positionnement technologique et choix d'architecture

La problématique de notre organisation concerne l'industrialisation d'un modèle de vision par ordinateur appliqué à la détection d'anomalies agricoles face à une volumétrie massive et dynamique d'images à haute résolution. Pour y répondre, **notre positionnement stratégique s'aligne sur les plus hauts standards théoriques et industriels identifiés (Maturité MLOps de Niveau 1/2)**. Notre solution concrétise ces concepts à travers une architecture hybride hautement sécurisée sur AWS, structurée en deux parties physiques indépendantes :

Partie 1 : Couche DataOps (Ingénierie des données à l'échelle)

Conformément aux préconisations de Mutya et Majety sur la spécialisation des pipelines [17] et de Jana sur la séparation stockage/calcul [18], nous isolons complètement la préparation des données. Un cluster éphémère **Amazon EMR** exécutant Apache Spark (PySpark) assure l'ingestion, le nettoyage et la réduction de dimensionnalité par ACP distribuée, libérant la plateforme MLOps de toute surcharge de calcul Big Data :

Données brutes → Data Lake S3 → Amazon EMR (PySpark) → Datasets structurés → Data Lake S3

Partie 2 : Couche ModelOps (Cycle de vie et déploiement standardisé)

Une fois les données prêtes, nous implémentons l'architecture MLOps native de référence d'AWS validée par Moreschini et al. [20]. L'ensemble du cycle de vie du modèle d'apprentissage profond est orchestré sous **Amazon SageMaker** (Studio, Model Registry, Endpoint), tandis que l'infrastructure réseau (VPC, sous-réseaux, IAM) et logicielle est provisionnée par code via **Terraform** et livrée automatiquement par des pipelines **GitHub Actions** [19] :

GitHub → GitHub Actions → Terraform → AWS → SageMaker Studio

Le flux de travail opérationnel :

1. **Exploration** : Le Data Scientist utilise son environnement sécurisé *Amazon SageMaker Studio* pour charger les datasets d'images nettoyés par EMR depuis le bucket S3.
2. **Entraînement et versionnage** : L'entraînement du réseau de neurones convolutif (CNN) est exécuté sur des instances managées. Le modèle finalisé est enregistré et versionné de manière centralisée au sein du *SageMaker Model Registry*.
3. **Mise en production sécurisée** : Après validation, le modèle est déployé sous forme de point de terminaison en temps réel (*Endpoint*) sécurisé par clé de chiffrement AWS KMS.





4. **Supervision et réentraînement continu (Perspectives) :** Pour opérationnaliser l'observabilité théorique de Nogare et al. [21], nous modélisons un pipeline de détection de dérive de données (*Data Drift*) basé sur un test statistique de Kolmogorov-Smirnov (seuil **KS > 0,20**) déclenchant automatiquement le réentraînement du modèle.

Cette séparation stricte garantit que la plateforme MLOps reste agile et performante, tandis que la lourdeur du traitement de la volumétrie croissante des images est intégralement absorbée par la puissance brute du cluster Big Data. Le chapitre suivant sera consacré à la méthodologie de ce projet, en détaillant l'analyse des besoins, les diagrammes modélisant le système, et la conception logique et physique de cette architecture Cloud.



MÉTHODOLOGIE DE CONCEPTION

Après avoir dressé l'état de l'art et défini notre positionnement technologique (une architecture hybride séparant l'ingénierie des données massives sur Amazon EMR et la plateforme MLOps sur Amazon SageMaker), ce chapitre détaille la démarche adoptée pour concevoir cette solution. Nous y aborderons la planification du projet, l'analyse approfondie des besoins et des acteurs, pour aboutir à la modélisation logique et physique de l'architecture déployée.

Sommaire

2.1	Planification du projet	28
2.2	Analyse du problème et définition des besoins	29
2.2.1	Analyse du problème	29
2.2.2	Besoins fonctionnels	29
2.2.3	Besoins non fonctionnels	32
2.2.4	Acteurs du système	33
2.2.5	Diagramme de cas d'utilisation	34
2.3	Conception de la solution	35
2.3.1	Architecture logique	35
2.3.2	Architecture physique	37
2.4	Résumé du chapitre	39



2.1 Planification du projet

La mise en place d'une infrastructure MLOps Cloud robuste nécessite une démarche itérative et incrémentale. Contrairement au développement logiciel classique, le passage à l'échelle d'un système d'intelligence artificielle implique une gestion complexe et évolutive des données (*Data Engineering*), de l'infrastructure en tant que code (IaC) et du cycle de vie des modèles.

Pour mener à bien ce projet, nous avons adopté une méthodologie Agile (inspirée du cadre Scrum), particulièrement adaptée aux environnements Cloud où l'expérimentation, la flexibilité et l'adaptation continue sont primordiales. Le projet s'est étalé sur une durée globale d'environ sept mois, découpée en **12 sprints de 2,5 semaines** chacun.

Cette planification s'est articulée autour de grandes phases logiques, reflétant directement notre double positionnement architectural :

- **Sprints 1 à 3 (Cadrage et Modélisation)** : Analyse des besoins fonctionnels et non fonctionnels, modélisation de l'architecture hybride et définition des exigences de sécurité et de conformité Cloud.
- **Sprint 4 (Ingénierie des données - Partie 1)** : Configuration du Data Lake (Amazon S3) et provisionnement du cluster Big Data éphémère (Amazon EMR). Développement des scripts PySpark pour l'ingestion, le nettoyage et le *Feature Engineering*.
- **Sprints 5 à 6 (Tests et validation intermédiaires)** : Évaluation des capacités de calcul distribué. Afin de tester et valider formellement nos scripts PySpark sans attendre les données privées finales, nous avons utilisé le jeu de données public *fruits-360* (disponible sur Kaggle). Cela a permis de prouver la scalabilité du prétraitement des images sur Amazon EMR avant de passer à l'étape suivante.
- **Sprints 7 à 9 (Plateforme MLOps - Partie 2)** : Mise en place de l'Infrastructure as Code avec Terraform, configuration des pipelines CI/CD via GitHub Actions et déploiement de l'environnement de développement Amazon SageMaker Studio pour l'équipe Data Science.
- **Sprints 10 à 12 (Validation architecturale et Intégration)** : Démonstration de la continuité de la chaîne de bout en bout. Nous avons validé le déclenchement des pipelines iac pour l'infrastructure SageMaker, VPC, User Roles, etc, via GitHub Actions, et finalisé la documentation technique du système.

L'adoption de ces sprints nous a permis de valider chaque brique technologique indépendamment (d'abord la préparation des données sur un dataset de référence, puis l'orchestration du modèle) avant de les assembler, réduisant ainsi les risques d'intégration.





2.2 Analyse du problème et définition des besoins

2.2.1 Analyse du problème

Le modèle de vision par ordinateur développé par le client de DESEMITs a prouvé son efficacité en local sur un petit jeu de donnée pour la détection d'anomalies sur les cultures agricoles. Cependant, son exécution reposait jusqu'ici sur des scripts locaux monolithiques. Face à la croissance exponentielle du volume d'images collectées (haute résolution), cette approche atteint ses limites physiques : saturation de la mémoire vive (RAM), temps de calcul prohibitifs et impossibilité de versionner ou de suivre la dégradation du modèle au fil des saisons agricoles.

Pour rendre ce modèle exploitable de manière durable, il est impératif de concevoir une infrastructure Cloud capable d'ingérer ces données massives, de distribuer la charge de prétraitement, et de fournir un cadre standardisé pour le réentraînement et le déploiement du modèle en production.

2.2.2 Besoins fonctionnels

Les besoins fonctionnels décrivent les actions concrètes et spécifiques que notre architecture hybride doit être capable d'exécuter. Pour répondre au défi de la volumétrie et de l'automatisation, ces besoins sont structurés autour de quatre piliers fondamentaux.

2.2.2.1 Pilier 1 : Stockage centralisé et Gestion du Data Lake

Le système doit fournir un référentiel unique pour rompre avec la fragmentation des données locales. Ce stockage doit permettre :

- L'ingestion et l'archivage sécurisé de volumes massifs d'images agricoles brutes.
- Le stockage organisé des jeux de données générés après prétraitement (répertoires train/, validation/, test/).
- La centralisation des artefacts de modèles et des journaux d'exécution.




FIGURE 2.1 – Modélisation fonctionnelle du flux de données vers le Data Lake





2.2.2.2 Pilier 2 : Prétraitement distribué (Ingénierie des données)

Face à l'incapacité d'une machine unique à traiter les images en un temps raisonnable, le système doit impérativement intégrer un moteur de calcul distribué pour l'équipe Data.

TABLEAU 2.1 – Exigences fonctionnelles liées au prétraitement des images agricoles

Fonctionnalité	Description de l'action système
Nettoyage	Filtrage automatique des images corrompues ou inexploitable avant analyse.
Transformation	Redimensionnement et normalisation des matrices d'images en parallèle.
Feature Engineering	Extraction de caractéristiques visuelles (via Analyse en Composantes Principales - ACP) pour réduire la dimensionnalité des données.
Génération de Data-sets	Sauvegarde automatisée des données propres et formatées vers le Data Lake.

2.2.2.3 Pilier 3 : Environnement de développement et CI/CD

L'architecture doit faciliter le travail quotidien des équipes techniques (Data Scientists et ingénieurs MLOps) tout en garantissant la reproductibilité du code.

- **Espace de travail en libre-service** : Fournir un environnement de développement interactif (Notebooks), directement connecté au Data Lake, sans exiger de configuration d'infrastructure de la part du Data Scientist.
- **Automatisation (IaC et CI/CD)** : Le déploiement de l'infrastructure sous-jacente et l'exécution des tests doivent être automatisés via des pipelines d'intégration et de livraison continues déclenchés à chaque modification du code source.






FIGURE 2.2 – Flux fonctionnel d'Intégration et de Déploiement Continus (CI/CD)

2.2.2.4 Pilier 4 : Orchestration ML, Registre et Déploiement

La plateforme doit encadrer le cycle de vie du modèle d'intelligence artificielle de manière reproductible et traçable, en isolant cette étape du traitement de la donnée brute.

TABEAU 2.2 – Exigences fonctionnelles liées à la Plateforme MLOps

Fonctionnalité	Description de l'action système
Orchestration (Pipelines)	Exécution séquentielle et automatisée de l'entraînement du modèle sur les données propres, suivie de son évaluation.
Registre de Modèles	Stockage centralisé et versionnage de chaque modèle entraîné, accompagné de ses métriques de performance et de son lignage.
Approbation	Mécanisme conditionnant le passage d'un modèle candidat vers la production (statut <i>Approved</i> ou <i>Rejected</i>).
Déploiement (Inférence)	Mise à disposition du modèle validé sous forme de point de terminaison (<i>Endpoint</i>) pour réaliser des prédictions sur de nouvelles images.



2.2.3 Besoins non fonctionnels

Les besoins non fonctionnels définissent les critères de qualité, de performance et de sécurité auxquels notre architecture Cloud doit impérativement satisfaire. Pour assurer la pérennité du système de vision par ordinateur du client, ces exigences ont été catégorisées en quatre axes majeurs :

2.2.3.1 Axe 1 : Scalabilité et Élasticité (Passage à l'échelle)

Face à la volumétrie massive et imprévisible des images agricoles, l'infrastructure doit être capable de s'adapter dynamiquement à la charge de travail.

- **Traitement Big Data** : Le cluster de calcul (*Amazon EMR*) doit pouvoir dimensionner automatiquement ses nœuds de travail (*Worker Nodes*) pour absorber le flux d'images lors d'une campagne de récolte, sans dégradation du temps de traitement.
- **Inférence ML** : Les points de terminaison (*Endpoints*) d'*Amazon SageMaker* doivent intégrer des politiques d'élasticité (*Auto Scaling*) pour gérer les pics de requêtes de prédiction en production, tout en maintenant une faible latence.

2.2.3.2 Axe 2 : Optimisation financière (Approche FinOps)

Étant donné l'intensité des calculs requis pour le traitement d'images haute résolution et l'extraction de caractéristiques par Analyse en Composantes Principales (ACP), la maîtrise des coûts est une contrainte stricte du cahier des charges.

- **Ressources éphémères** : Le cluster de préparation des données (Data Engineering) doit être provisionné à la demande et détruit de manière automatisée dès la fin de la génération des datasets. Il ne doit y avoir aucune facturation de ressources de calcul inactives.
- **Instances Spot** : L'architecture doit prioriser l'utilisation de la capacité excédentaire d'AWS (*Instances Spot*) pour les tâches de traitement par lots, permettant de réduire les coûts de calcul de manière significative (jusqu'à 70% d'économie).

2.2.3.3 Axe 3 : Sécurité, Isolement et Conformité

La manipulation de données propriétaires (images de cultures, modèles d'entreprise) nécessite un cloisonnement strict du système, conformément aux bonnes pratiques Cloud.

- **Isolation réseau (VPC)** : L'ensemble des ressources (S3, EMR, SageMaker Studio) doit être déployé au sein d'un Réseau Privé Virtuel (*Amazon VPC*), empêchant tout accès direct depuis l'Internet public.
- **Gestion des accès (IAM)** : Application stricte du « principe du moindre privilège ». Chaque service AWS (ex : le cluster EMR) et chaque pipeline d'automatisation (*GitHub Actions*) ne doit disposer que des autorisations strictement nécessaires à son exécution.





- **Chiffrement** : Toutes les données stockées dans le Data Lake ainsi que les artefacts de modèles doivent être chiffrés au repos et en transit via le service *AWS KMS* (Key Management Service).

2.2.3.4 Axe 4 : Maintenabilité et Supervision (SRE)

L'architecture, bien que complexe sous le capot, doit rester observable et facilement maintenable par les équipes techniques.

- **Supervision centralisée** : Tous les journaux d'exécution (*logs*) d'EMR et les métriques de performance des modèles SageMaker doivent être centralisés dans *Amazon CloudWatch* pour faciliter le débogage.
- **Reproductibilité (IaC)** : Toute modification de l'infrastructure doit pouvoir être reproduite et auditée. L'utilisation de *Terraform* garantit que l'environnement est versionné et auditable comme du code classique.

TABLEAU 2.3 – Matrice de synthèse des besoins non fonctionnels de l'architecture

Catégorie	Exigence technique	Solutions & Services AWS
Élasticité	Redimensionnement automatique selon la charge de données	<i>Amazon EMR / SageMaker Auto Scaling</i>
FinOps	Utilisation de clusters éphémères et d'instances à coût réduit	Instances <i>Amazon EC2 Spot</i>
Sécurité	Chiffrement des données, moindre privilège et isolement réseau	<i>AWS KMS, AWS IAM, Amazon VPC</i>
Supervision	Traçabilité centralisée des métriques et des erreurs	<i>Amazon CloudWatch</i>
Maintenabilité	Infrastructure déployable par code, reproductible et versionnée	<i>Terraform, GitHub Actions</i>

2.2.4 Acteurs du système

L'industrialisation d'un modèle de vision par ordinateur via le MLOps est un effort pluridisciplinaire. Le système conçu implique l'interaction de plusieurs acteurs aux profils techniques distincts. Nous les avons répartis en deux grandes catégories : l'équipe Data (qui manipule la donnée et le modèle) et l'équipe Infrastructure (qui gère les ressources Cloud).





TABLEAU 2.4 – Cartographie des acteurs et de leurs responsabilités dans le système

Acteur	Rôle et interactions avec le système
Équipe Data	
Data Engineer (Ingénieur Données)	Responsable de la première partie de l'architecture. Il développe et exécute les scripts de traitement distribué (PySpark) sur le cluster <i>Amazon EMR</i> . Il s'assure que les images sont correctement ingérées, nettoyées, transformées (ACP), et sauvegardées de manière structurée dans le Data Lake (<i>Amazon S3</i>).
Data Scientist (Scientifique des Données)	Utilisateur principal de la plateforme MLOps. Depuis son environnement <i>Amazon SageMaker Studio</i> , il consomme les données propres préparées par le Data Engineer. Il conçoit le code du modèle, lance les tâches d'entraînement (<i>Training Jobs</i>) et enregistre les versions candidates du modèle dans le registre (<i>Model Registry</i>).
Lead Data (Responsable Data)	Superviseur de la qualité algorithmique. Il analyse les métriques de performance des modèles enregistrés par les Data Scientists. C'est lui qui déclenche manuellement ou valide l'approbation d'un modèle dans le registre, autorisant ainsi son passage vers l'environnement de production.
Équipe Infrastructure	
Administrateur Cloud (Ingénieur MLOps / Cloud)	Garant de la stabilité, de la sécurité et des coûts (FinOps). Il déploie l'infrastructure sous-jacente en tant que code (<i>Terraform</i>) via les pipelines CI/CD (<i>GitHub Actions</i>). Il configure le réseau (VPC), gère les permissions d'accès (IAM) et supervise l'état des serveurs et les journaux d'erreurs via <i>Amazon CloudWatch</i> .

2.2.5 Diagramme de cas d'utilisation

La modélisation UML (Unified Modeling Language) permet de cartographier formellement les interactions fonctionnelles entre ces acteurs et le système Cloud. Le diagramme de cas d'utilisation présenté ci-dessous illustre le périmètre de notre architecture hybride, en mettant en évidence la séparation des responsabilités.

Ce diagramme s'articule autour des macro-processus suivants :

- **Gestion des données massives** : Ingestion des images brutes et déclenchement du pré-traitement distribué (réservé au Data Engineer).
- **Cycle de vie du modèle** : Développement, entraînement et enregistrement du modèle (réservé au Data Scientist).
- **Gouvernance et Déploiement** : Approbation du modèle (Lead Data) et orchestration de l'infrastructure globale (Administrateur Cloud).






FIGURE 2.3 – Diagramme de cas d'utilisation du système hybride (Data Engineering & MLOps)

2.3 Conception de la solution

Sur la base de l'analyse des besoins fonctionnels et non fonctionnels, nous avons conçu une architecture Cloud distribuée capable de résoudre les problèmes de saturation locale rencontrés par le client. Le principe fondamental qui dicte cette conception est le **découplage strict entre le stockage des données et la puissance de calcul**, une bonne pratique incontournable dans l'ingénierie des données massives.

2.3.1 Architecture logique

L'architecture logique modélise le flux de traitement de l'information et l'orchestration des processus, en faisant abstraction des composants matériels ou des serveurs physiques sous-jacents. Ce modèle s'articule autour d'un pipeline divisé en deux grands sous-systèmes interdépendants, conformément à notre positionnement : le sous-système de préparation des données (*Data Engineering*) et le sous-système d'orchestration des modèles (*MLOps*).





Le flux logique de notre système suit un graphe orienté qui se décompose en quatre étapes majeures :

1. **Ingestion et Stockage centralisé** : L'opérateur métier ou le système de collecte dépose un jeu d'images agricoles brutes dans le référentiel central (*Data Lake*). Cet espace agit comme l'unique source de vérité (*Single Source of Truth*) pour l'ensemble du système, isolant les données brutes des données transformées.
2. **Prétraitement distribué (Pipeline Data)** : Le dépôt des données justifie l'instanciation du moteur de calcul distribué. Ce dernier parallélise les tâches lourdes de préparation : nettoyage des images, redimensionnement, et surtout la réduction de dimensionnalité via une Analyse en Composantes Principales (ACP). Les caractéristiques extraites (*features*) sont re-sauvegardées de manière structurée dans le Data Lake, allégeant ainsi le volume d'information.
3. **Orchestration et Entraînement (Pipeline ML)** : Une fois les données préparées, le moteur d'orchestration MLOps prend le relais. Il charge les données propres et exécute les scripts d'apprentissage du modèle de vision par ordinateur. Cette étape inclut la validation des performances du modèle candidat sur un jeu de test.
4. **Gouvernance et Inférence** : Le modèle entraîné est versionné et stocké dans un registre logique (*Model Registry*). Après validation (approbation) par l'équipe Data, il est déployé sur un point de terminaison (*Endpoint*) pour réaliser des prédictions (inférence) sur de nouvelles images. Les résultats prédictifs (détection d'anomalies) sont ensuite sauvegardés dans le Data Lake, clôturant ainsi le cycle logique.

Cette séparation logique garantit que la complexité et la lourdeur du traitement de la donnée brute n'interfèrent pas avec la plateforme de modélisation, assurant ainsi la fluidité et la répétabilité du cycle de vie du modèle.






FIGURE 2.4 – Architecture logique du pipeline de traitement distribué et d’orchestration MLOps

2.3.2 Architecture physique

L’architecture physique matérialise le flux logique décrit précédemment en s’appuyant exclusivement sur les services Cloud managés d’Amazon Web Services (AWS). Conformément à notre positionnement hybride, cette infrastructure déploie des ressources distinctes pour le traitement massif d’un côté, et pour l’orchestration du Machine Learning de l’autre, tout en garantissant un environnement hautement sécurisé.

Les composants physiques de notre architecture se répartissent en quatre couches fonctionnelles :

2.3.2.1 Couche 1 : Sécurité et Réseau (Foundations)

Toute l’architecture repose sur une fondation sécurisée pour protéger les données propriétaires du client :

- **Amazon VPC (Virtual Private Cloud)** : L’ensemble des ressources de calcul et des espaces de travail est isolé dans un réseau privé virtuel. Cela permet de contrôler strictement le trafic entrant et sortant via des groupes de sécurité (*Security Groups*) [7].
- **AWS IAM (Identity and Access Management)** : La gouvernance des accès est dictée par des rôles IAM stricts. Par exemple, le cluster EMR ne possède que les droits de lecture/écriture sur le bucket S3 dédié, garantissant l’application du principe de moindre privilège [7].

2.3.2.2 Couche 2 : Sous-système Data Engineering (Partie 1)

Cette couche absorbe la charge lourde du traitement des images agricoles :





- **Amazon S3 (Data Lake)** : Service de stockage objet agissant comme le cœur de l'architecture. Il stocke les images brutes, les données transformées (après ACP) et les artefacts des modèles de manière hautement durable et chiffrée.
- **Amazon EMR (Elastic MapReduce)** : Le moteur de calcul distribué (utilisant *Apache Spark / PySpark*). Pour respecter nos contraintes FinOps, ce cluster est **éphémère** : il est instancié avec des instances *Spot* (à coût réduit) uniquement pour la durée de la génération des datasets, puis détruit automatiquement.

2.3.2.3 Couche 3 : Plateforme MLOps (Partie 2)

Une fois les jeux de données préparés sur S3, cette couche prend le relais pour le cycle de vie de l'IA :

- **Amazon SageMaker Studio** : L'environnement de développement (*IDE*) managé fourni aux Data Scientists. Il permet de développer le code ML dans des Notebooks Jupyter connectés aux données de S3.
- **SageMaker Model Registry** : Un registre physique centralisant les versions des modèles entraînés et gérant leur statut d'approbation (ex : *PendingManualApproval* vers *Approved*) [7].
- **SageMaker Endpoints** : L'infrastructure d'inférence. Les modèles validés y sont déployés sous forme d'API REST auto-scalables pour réaliser des prédictions sur de nouvelles images.

2.3.2.4 Couche 4 : Automatisation et Supervision (CI/CD et IaC)

Pour relier les composants et assurer la reproductibilité de l'infrastructure :

- **Terraform & GitHub Actions** : L'infrastructure AWS et les pipelines MLOps ne sont pas cliqués manuellement, mais définis sous forme de code (*Infrastructure as Code*). GitHub Actions orchestre le déploiement continu des ressources via Terraform, garantissant que chaque environnement peut être recréé à l'identique.
- **Amazon CloudWatch** : Service de supervision qui collecte les métriques d'utilisation (CPU, RAM) des clusters EMR et les journaux d'erreurs des modèles SageMaker pour alerter l'Administrateur Cloud en cas de défaillance.






FIGURE 2.5 – Architecture physique détaillée de la solution MLOps sur Amazon Web Services

2.4 Résumé du chapitre

Ce chapitre a permis de traduire la problématique d'ingénierie soulevée par le client en une solution technique concrète et rigoureusement modélisée. En appliquant une méthodologie de conception itérative basée sur des Sprints, nous avons identifié les limites critiques de l'approche locale initiale et formalisé des besoins stricts en matière de passage à l'échelle, de sécurité et d'optimisation financière (FinOps).

L'analyse des acteurs a clarifié la répartition des tâches au sein de l'organisation : le *Data Engineer* et le *Data Scientist* interagissant avec les données et les modèles, tandis que le *Lead Data* et l'*Administrateur Cloud* assurent la gouvernance et le maintien de l'infrastructure.

Enfin, la conception architecturale a mis en évidence notre choix stratégique fondamental : un découplage physique via une architecture hybride. Le traitement massif des données est intégralement délégué à un sous-système Big Data éphémère (Amazon EMR et S3), tandis que l'orchestration, le registre et le déploiement du modèle d'intelligence artificielle reposent sur une plateforme MLOps standardisée (Amazon SageMaker, couplé à GitHub et Terraform).

Ces fondations méthodologiques et architecturales étant désormais solidement établies, le chapitre suivant sera consacré à l'implémentation pratique de cette architecture sur le Cloud AWS et à l'évaluation de ses performances.

IMPLÉMENTATION ET RÉSULTATS

Ce chapitre concrétise la mise en œuvre de la solution d'architecture hybride conçue au chapitre précédent. Il détaille l'implémentation matérielle et logicielle du pipeline de traitement d'images et d'inférence, en s'appuyant sur l'automatisation de l'infrastructure, le calcul distribué et la gouvernance MLOps.

Sommaire

3.1	Infrastructure et automatisation	41
3.1.1	Provisionnement automatisé par Terraform	41
3.1.2	Structuration et sécurité du Data Lake (Amazon S3)	43
3.1.3	Intégration CI/CD via GitHub Actions	44
3.2	Implémentation du pipeline Data Engineering	46
3.2.1	Configuration du cluster distribué éphémère	46
3.2.2	Développement du traitement d'images distribué sous PySpark	48
3.3	Implémentation de la plateforme MLOps	49
3.3.1	Espace de travail collaboratif (SageMaker Studio)	49
3.3.2	Pipeline d'entraînement et registre de modèles (Model Registry)	50
3.3.3	Déploiement du service d'inférence (SageMaker Endpoint)	51
3.4	Résultats, métriques et analyse des coûts	52
3.4.1	Protocole expérimental et supervision en temps réel	52
3.4.2	Évaluation technique des performances	53
3.4.3	Analyse financière et évaluation FinOps	53
3.5	Résumé du chapitre	55



3.1 Infrastructure et automatisation


La mise en production de notre architecture sur Amazon Web Services (AWS) repose sur une approche d'automatisation moderne. Afin de garantir la répétabilité technique, de s'affranchir des erreurs inhérentes aux configurations manuelles et d'assurer une traçabilité complète de l'environnement, l'intégralité des fondations de la plateforme est déployée par code.

3.1.1 Provisionnement automatisé par Terraform

L'infrastructure Cloud sous-jacente est entièrement déclarée et provisionnée à l'aide de **Terraform**. Grâce au langage HCL (*HashiCorp Configuration Language*), nous décrivons l'état cible des ressources qui composent l'environnement.

- **Gestion centralisée de l'état (State File) :** L'état réel des composants AWS déployés est consigné dans un fichier `terraform.tfstate`. Afin de permettre la collaboration et d'éviter des modifications concurrentes conflictuelles, ce fichier est stocké de manière sécurisée dans un bucket Amazon S3 privé, avec un mécanisme de verrouillage dynamique géré par une table Amazon DynamoDB.
- **Modularité et reproductibilité :** L'écriture des fichiers HCL est structurée en modules réutilisables permettant d'isoler logiquement les couches réseau, de sécurité et de stockage. Ce partitionnement permet de déployer des environnements de développement, de validation ou de production strictement identiques en limitant l'introduction de dérives de configuration.





```
1 resource "aws_vpc" "main" {
2   cidr_block      = "10.0.0.0/16"
3   enable_dns_hostnames = true
4   enable_dns_support = true
5 }
6
7 resource "aws_flow_log" "main" {
8   iam_role_arn    = aws_iam_role.vpc_flow_logs_role.arn
9   log_destination = aws_cloudwatch_log_group.main.arn
10  traffic_type     = "ALL"
11  vpc_id           = aws_vpc.main.id
12 }
13
14 resource "aws_cloudwatch_log_group" "main" {
15   name                = "/aws/vpc/main-flow-logs"
16   retention_in_days   = 365
17 }
18
19 resource "aws_subnet" "private" {
20   vpc_id            = aws_vpc.main.id
21   cidr_block        = "10.0.128.0/20"
22   availability_zone = "${var.region}a"
23   tags = {
24     Name = "Private"
25   }
26 }
27
28 resource "aws_subnet" "private_2" {
29   vpc_id            = aws_vpc.main.id
30   cidr_block        = "10.0.0.0/20"
31   availability_zone = "${var.region}b"
32   tags = {
33     Name = "Private"
34   }
35 }
```

FIGURE 3.1 – Extrait du script de configuration Terraform (Fichiers HCL pour le réseau)

- **Réseau privé virtuel et Isolation (Amazon VPC) :** Le script Terraform instancie un **Amazon VPC** isolé. Ce réseau est découpé de manière étanche en sous-réseaux publics (pour les passerelles et l'accès externe contrôlé) et sous-réseaux privés (hébergeant le cluster Amazon EMR et les environnements d'entraînement et d'inférence SageMaker). Des tables de routage, des passerelles NAT (*NAT Gateways*) et des points de terminaison de VPC (*VPC Endpoints*) sont configurés par code pour permettre aux composants internes de communiquer en toute sécurité sans jamais exposer les données ou les instances sur l'Internet public.
- **Contrôle d'accès et Moindre privilège (AWS IAM) :** Terraform applique une politique de sécurité de type « défense en profondeur » en provisionnant des rôles et des politiques d'accès **AWS IAM** extrêmement restrictifs. Chaque service (comme le cluster de calcul EMR ou le service d'intégration GitHub Actions) se voit attribuer un rôle d'exécution dédié limitant ses droits d'action aux seules ressources S3 ou de calcul qui lui sont indispensables.






FIGURE 3.2 – Configuration réseau sous Amazon VPC et isolation des sous-réseaux

3.1.2 Structuration et sécurité du Data Lake (Amazon S3)

Le stockage centralisé de la plateforme est matérialisé par un bucket **Amazon S3**. Ce service de stockage objet fait office de référentiel unique et centralisé (*Single Source of Truth*), garantissant le découplage complet entre le stockage durable de la donnée et la puissance de calcul activée à la demande.

Pour garantir une gouvernance de données rigoureuse et éviter l'apparition d'un espace de stockage désordonné (*Data Swamp*), le bucket est structuré de façon hermétique en répertoires fonctionnels correspondant aux différentes étapes du cycle de vie de la donnée :



TABLEAU 3.1 – Structuration logique et rôles des répertoires du Data Lake Amazon S3

Répertoire S3	Description et rôle fonctionnel au sein du pipeline
/raw/	Espace d'ingestion et d'archivage hautement sécurisé pour les images agricoles brutes.
/PCA/	Stockage structuré des jeux de données de caractéristiques extraites (features ACP) avec les sous-dossiers /train/, /validation/ et /test/.
/models/	Zone réservée au stockage des artefacts physiques des modèles entraînés, des configurations et de leurs poids associés.
/results/	Répertoire d'écriture des fichiers de résultats d'inférence et des détections d'anomalies.
/error-logs/	Centralisation automatique des journaux d'exécution, de calcul et de débogage du cluster EMR.
/studios/	Espace de persistance pour sauvegarder l'état et le code des espaces de travail et Notebooks des utilisateurs.

Toutes les données stockées dans ce Data Lake ainsi que les métadonnées associées sont chiffrées au repos et en transit en utilisant des clés de chiffrement gérées par le client via le service **AWS KMS** (*Key Management Service*). De plus, afin de respecter les exigences strictes de souveraineté et de conformité réglementaire (comme le RGPD), l'ensemble du stockage est géographiquement localisé et confiné dans la région européenne AWS d'Irlande (eu-west-1).

```

/mnt/dtamboudisk/rapport_ing_aia$ aws s3 ls s3://desemits-s3-agri-intern-dt/
PRE PCA/
PRE Results_features/
PRE Test-grand/
PRE Test/
PRE error-logs/
PRE models/
PRE studios/
215 bootstrap-emr.sh

```

FIGURE 3.3 – Organisation de l'arborescence du Data Lake dans le bucket Amazon S3

3.1.3 Intégration CI/CD via GitHub Actions

Le déploiement et la mise à jour continue de l'infrastructure et des applications sont entièrement automatisés par des pipelines d'intégration et de livraison continues (CI/CD).

- **Hébergement et Versionnage unifié** : L'ensemble du code de configuration Terraform, des scripts de traitement PySpark et des codes d'apprentissage machine est centralisé et versionné au sein d'un dépôt sécurisé **GitHub**.



- **Automatisation des pipelines (GitHub Actions) :** À chaque modification du code d'infrastructure poussée sur la branche principale du dépôt, un workflow d'intégration **GitHub Actions** est automatiquement déclenché. Ce pipeline réalise des tests de validation syntaxique (*linting*), puis exécute automatiquement la séquence d'actions Terraform (terraform plan suivi de terraform apply) sur le compte AWS.
- **Sécurisation des secrets applicatifs :** Pour permettre à GitHub Actions d'interagir avec les APIs d'AWS de manière hautement sécurisée, une connexion de confiance est établie via un connecteur sécurisé, évitant l'usage de clés d'accès statiques permanentes stockées en clair. Les informations d'identification sensibles et jetons de configuration sont stockés de manière robuste et chiffrée dans **AWS Secrets Manager**.




FIGURE 3.4 – Historique d'exécution du pipeline de provisionnement d'infrastructure IaC dans GitHub Actions




FIGURE 3.5 – Étape d'exécution d'un pipeline de provisionnement d'infrastructure IaC dans GitHub Actions Terraform apply

3.2 Implémentation du pipeline Data Engineering

Une fois l'infrastructure réseau et de stockage provisionnée par Terraform, la seconde phase de l'implémentation consiste à déployer et configurer le sous-système dédié au traitement des données massives. Ce pipeline de traitement Big Data a pour unique responsabilité de transformer les images agricoles brutes en descripteurs mathématiques exploitables, déchargeant ainsi la plateforme MLOps de la lourdeur des calculs de préparation.

3.2.1 Configuration du cluster distribué éphémère

Le moteur de calcul distribué repose sur le service managé **Amazon EMR** (Elastic MapReduce). Pour concrétiser nos engagements en matière de performance technique et d'optimisation





budgétaire (FinOps), le déploiement du cluster applique les choix de configuration suivants :

- **Topologie du cluster** : Le cluster est configuré selon une architecture de type maître/esclaves. Il se compose d'un nœud maître (*Master Node*), chargé de coordonner l'exécution des calculs et de distribuer les tâches, et de quatre nœuds de travail (*Worker Nodes*) responsables de l'exécution parallèle des calculs sur les partitions de données.
- **Politique FinOps d'instances Spot** : Afin de réduire drastiquement les coûts opérationnels liés à l'allocation de serveurs de calcul, les nœuds de travail exploitent des instances **Amazon EC2 Spot**. Ces instances tirent parti de la capacité excédentaire d'AWS à un coût réduit de près de 70 % par rapport au tarif standard à la demande.
- **Éphémérité et extinction automatique** : Pour éviter toute facturation inutile de ressources de calcul inactives, le cluster est configuré pour être strictement éphémère. Une politique d'arrêt automatique est programmée par l'administrateur, déclenchant l'auto-destruction complète du cluster après une période d'inactivité continue de deux heures.
- **Script de démarrage (Bootstrap Action)** : Lors de l'initialisation du cluster, un script Shell personnalisé nommé `bootstrap-emr.sh` est exécuté automatiquement sur l'ensemble des nœuds. Ce script installe les dépendances Python nécessaires au traitement d'images (telles que Pillow, NumPy et SciPy) avant le démarrage de l'exécuteur Spark.





FIGURE 3.6 – Console AWS présentant le statut actif et la topologie du cluster Amazon EMR (1 Master / 4 Workers)

L'administration et la soumission des tâches de calcul s'effectuent par une liaison sécurisée. L'administrateur réseau établit une session sécurisée via le protocole SSH vers le nœud maître, ce qui permet de superviser l'état du gestionnaire de ressources YARN (*Yet Another Resource Negotiator*) et de soumettre les jobs d'analyse.





Pour manipuler des pétaoctets d’images agricoles sans saturer la mémoire des serveurs physiques, nous avons développé un script d’ingestion et de transformation unifié à l’aide de l’API **PvSpark** (Apache Spark pour Python).

- **Ingestion parallèle depuis Amazon S3** : Les images agricoles brutes stockées dans le dossier /raw/ du Data Lake sont lues sous forme de flux binaires distribués. Spark divise automatiquement la collection d'images en de multiples partitions réparties sur les nœuds de travail.
- **Prétraitement et nettoyage distribué** : Chaque image de la partition est nettoyée individuellement à l'aide d'une fonction d'analyse parallélisée (*PySpark UDF - User Defined Function*). Les images corrompues ou de taille invalide sont automatiquement écartées et loguées dans le répertoire /error-logs/. Les images valides sont redimensionnées et converties en matrices de pixels normalisées.
- **Réduction de dimensionnalité par ACP** : Les images à haute résolution imposent un volume de caractéristiques trop lourd pour l'entraînement d'un modèle d'apprentissage. Pour lever ce verrou, une Analyse en Composantes Principales (**ACP**) distribuée est exécutée à l'aide de la bibliothèque Spark MLlib. Ce traitement mathématique projette les



matrices de pixels sur un espace de dimension inférieure en conservant l'essentiel de la variance statistique de l'image.

- **Partitionnement et écriture des jeux de données :** Les descripteurs extraits (features ACP) sont structurés, puis automatiquement segmentés en trois jeux de données distincts : entraînement (train/), validation (validation/) et test (test/). Ces jeux de données nettoyés sont sauvegardés au format optimisé Parquet directement dans le répertoire /PCA/ du Data Lake Amazon S3, prêts pour l'étape de modélisation.

3.3 Implémentation de la plateforme MLOps

Une fois les données agricoles nettoyées, transformées et réduites par l'Analyse en Composantes Principales (ACP) sur le cluster Amazon EMR, la plateforme MLOps prend le relais. Cette section détaille la mise en œuvre pratique de l'environnement de modélisation, de la gouvernance des modèles entraînés et de leur déploiement sous forme de service d'inférence sécurisé et scalable à l'aide d'Amazon SageMaker.

3.3.1 Espace de travail collaboratif (SageMaker Studio)

L'activité quotidienne de modélisation et d'expérimentation du Data Scientist est centralisée au sein d'**Amazon SageMaker Studio**, un environnement de développement intégré (IDE) entièrement managé sur AWS.

- **Workspace Jupyter standardisé :** SageMaker Studio fournit des instances de Notebooks Jupyter préconfigurées avec les frameworks de Machine Learning et de Deep Learning les plus populaires. L'utilisateur dispose ainsi d'un environnement prêt à l'emploi, s'affranchissant des tâches complexes d'installation locale ou de gestion de dépendances matérielles (telles que les pilotes CUDA pour l'accélération GPU).
- **Accès sécurisé et direct au Data Lake S3 :** L'espace de travail est rattaché de manière transparente aux répertoires de données du bucket S3. Grâce au rôle IAM restrictif attribué à l'espace de travail de l'utilisateur, le Data Scientist peut charger instantanément les données propres et dimensionnellement réduites (les fichiers Parquet situés sous le répertoire /PCA/) sans avoir à rapatrier physiquement les données sur son poste local.






FIGURE 3.8 – Espace de travail Jupyter actif au sein de la console Amazon SageMaker Studio

3.3.2 Pipeline d'entraînement et registre de modèles (Model Registry)

Le passage à l'échelle et la fiabilité de notre système exigent que chaque modèle candidat soit entraîné, évalué et consigné de manière rigoureuse au sein d'un registre logique unique.

- **Exécution du Training Job :** L'apprentissage du modèle de vision par ordinateur est instancié à travers un job d'entraînement (*Training Job*) dédié sur SageMaker. Ce processus isole la puissance de calcul nécessaire à l'apprentissage en démarrant temporairement une instance optimisée pour le calcul intensif, qui charge les scripts d'apprentissage depuis GitHub, ingère les features ACP du répertoire /PCA/train/, puis s'éteint automatiquement





dès la fin du calcul.

- **Sauvegarde des artefacts** : À l'issue de la phase d'apprentissage, les poids du modèle, ses fichiers de configuration et ses métadonnées de performance sont packagés sous forme d'archive compressée et sauvegardés de façon permanente dans le répertoire /models/ du Data Lake S3.
- **Enregistrement dans le Model Registry** : Le modèle entraîné est automatiquement référencé dans le **SageMaker Model Registry**. Ce composant de gouvernance centralise toutes les versions du modèle de vision par ordinateur en conservant son lignage de données complet (hyperparamètres, version du code GitHub et jeu de données S3 utilisé pour l'apprentissage) ainsi que les métriques d'évaluation obtenues sur le jeu de test.




FIGURE 3.9 – Interface du registre de modèles (Model Registry) présentant les versions et l'historique d'approbation

3.3.3 Déploiement du service d'inférence (SageMaker Endpoint)

Le déploiement du modèle approuvé pour la production s'appuie sur le mécanisme de transition d'état et d'exposition de point de terminaison.

- **Processus d'approbation manuelle** : Tout modèle candidat enregistré dans le Model Registry se voit initialement attribuer le statut d'attente (PendingManualApproval). Le **Lead Data** évalue les métriques associées (précision, rappel, matrice de confusion) et valide manuellement le modèle en basculant son statut à approuvé (Approved).
- **Déploiement automatisé du point de terminaison** : La transition vers le statut Approved déclenche automatiquement le déploiement du modèle sur une infrastructure d'inférence managée via un **SageMaker Endpoint**. Ce point de terminaison expose le modèle de vision par ordinateur sous la forme d'une API REST hautement disponible et sécurisée au sein du VPC.
- **Collecte et stockage des résultats d'inférence** : Lorsqu'un utilisateur (Data Analyst) soumet de nouvelles images agricoles via l'API, le point de terminaison exécute la prédiction en temps réel et renvoie le diagnostic (détection d'anomalies). Les prédictions ainsi





générées sont automatiquement horodatées et écrites dans le répertoire `/results/` de notre Data Lake S3 pour permettre un audit futur et le suivi des performances du système.

3.4 Résultats, métriques et analyse des coûts

Cette section présente les résultats expérimentaux obtenus lors de l'exécution de notre architecture de bout en bout. Nous y évaluons les performances techniques du traitement distribué, l'efficacité de la supervision en temps réel, ainsi qu'un bilan financier rigoureux validant notre démarche d'optimisation des coûts (FinOps) à l'aide de données d'exécution concrètes.

3.4.1 Protocole expérimental et supervision en temps réel

Pour valider la robustesse de l'architecture physique déployée sur AWS, un protocole de test rigoureux a été défini. Le pipeline a été exécuté sur un volume massif d'images agricoles haute résolution simulant une campagne de collecte réelle sur le terrain.

La supervision active et la traçabilité de cette exécution ont été assurées par la combinaison de deux outils majeurs du Cloud :

- **L'interface Spark UI** : Accessible de manière sécurisée via le tunnel SSH établi sur le nœud maître de l'EMR, la console graphique Spark UI a permis de suivre en temps réel la répartition des tâches sur les différents nœuds de travail. Elle détaille le découpage logique des traitements en *Jobs*, *Stages* et *Tasks*, facilitant l'identification d'éventuels déséquilibres de charge (*data skew*) ou de goulots d'étranglement réseau lors du traitement d'images.
- **Amazon CloudWatch** : Ce service a centralisé l'ensemble des métriques d'infrastructure (taux d'utilisation CPU, consommation de mémoire vive RAM) des instances EC2 du cluster EMR et de l'Endpoint SageMaker. Des alarmes CloudWatch ont été configurées pour notifier automatiquement l'administrateur en cas de dépassement des seuils critiques de mémoire ou d'anomalies de conteneurs.



Job Id (Job Group)	Description	Submitted	Duration	Stages: Succeeded/Total	Tasks (for all stages): Succeeded/Total
0 (4)	Listing leaf files and directories for 131 paths: s3://desemits-s3-agi-intern-dt/Test/Apple Braeburn, ... load at NativeMethodAccessorImpl.java:0	2026/07/13 03:08:42	10 s	1/1	131/131
1 (4)	Job group for statement 4 showString at NativeMethodAccessorImpl.java:0	2026/07/13 03:08:54	1 s	1/1	1/1
2 (11)	Job group for statement 11 parquet at NativeMethodAccessorImpl.java:0	2026/07/13 03:09:54	9.9 min	1/1	709/709
3 (11)	Job group for statement 11 parquet at NativeMethodAccessorImpl.java:0	2026/07/13 03:19:48	7.6 min	1/1 (1 skipped)	24/24 (209 skipped)
4 (13)	Job group for statement 13 parquet at NativeMethodAccessorImpl.java:0	2026/07/13 03:28:06	0.2 s	1/1	1/1
5 (13)	Job group for statement 13 showString at NativeMethodAccessorImpl.java:0	2026/07/13 03:28:06	0.5 s	1/1	1/1
6 (13)	Job group for statement 13 first at PCA.scala:44	2026/07/13 03:28:07	2 s	1/1	1/1
7 (13)	Job group for statement 13 first at RowMatrix.scala:52	2026/07/13 03:28:08	1.0 s	1/1	1/1
8 (13)	Job group for statement 13 treeAggregate at Statistics.scala:58	2026/07/13 03:28:09	11 s	1/1	3/3
9 (13)	Job group for statement 13 isEmpty at RowMatrix.scala:441	2026/07/13 03:28:20	0.3 s	1/1	1/1
10 (13)	Job group for statement 13	2026/07/13 03:28:21	15 s	1/1	3/3

FIGURE 3.10 – Interface Apache Spark UI présentant le suivi d'exécution des tâches distribuées sur le cluster

3.4.2 Évaluation technique des performances

L'évaluation technique confirme la viabilité de l'approche par découplage strict entre le stockage durable (S3) et le calcul éphémère (EMR/PySpark et SageMaker).

- **Résolution des verrous de saturation** : Contrairement aux tests initiaux menés sur des machines locales qui saturaient rapidement en mémoire vive (RAM) lors de la manipulation d'images haute résolution, le cluster distribué a traité l'ensemble du jeu de données sans aucune interruption. Les nœuds de travail ont parallélisé efficacement les opérations d'ingestion et de réduction de dimension par ACP.
- **Stabilité de l'infrastructure de calcul** : Spark a géré de manière autonome la répartition des partitions de données. Le temps d'exécution global a été réduit de manière quasi linéaire par rapport au nombre d'instances de calcul de type Worker allouées, prouvant la scalabilité horizontale du cluster éphémère Amazon EMR.
- **Disponibilité de l'Endpoint d'inférence** : Le point de terminaison de SageMaker a maintenu un temps de réponse extrêmement stable, tout en assurant l'auto-scaling face aux variations simulées du trafic de requêtes de prédiction.

3.4.3 Analyse financière et évaluation FinOps

L'un des objectifs majeurs de ce travail réside dans la maîtrise rigoureuse des coûts d'exploitation dans le Cloud. L'évaluation financière démontre que l'application de principes FinOps stricts permet de concilier la puissance du Big Data et la viabilité budgétaire.

Deux leviers principaux ont permis cette optimisation massive :





- **L'utilisation d'instances EC2 Spot** : L'allocation d'instances Spot pour les quatre nœuds de travail du cluster EMR a permis d'obtenir une réduction moyenne de 72 % du coût horaire du calcul distribué par rapport au tarif standard à la demande, sans aucun impact sur la complétude des traitements (les tâches étant tolérantes aux pannes).
- **L'éphémérité du cluster de calcul** : Grâce à la configuration d'une politique d'auto-destruction après deux heures d'inactivité, le cluster EMR n'a été facturé que pour la durée stricte des traitements de préparation. Les ressources de calcul n'ont généré aucun surcoût inutile en dehors des fenêtres d'exécution.

TABLEAU 3.2 – Répartition des coûts mensuels réels par service AWS (approche FinOps)

Service AWS	Coût mensuel (\$)	Justification opérationnelle et optimisation
Amazon Virtual Private Cloud	85,47	Trafic de données interne sécurisé, passerelles NAT et gestion des sous-réseaux.
EC2 - Other	27,26	Volumes EBS, adresses IP élastiques et ressources associées aux instances.
Amazon EC2 (Compute)	3,52	Instances de calcul pour l'exécution des traitements et charges de travail.
AWS Key Management Service	0,72	Gestion des clés de chiffrement pour la sécurité des données au repos et en transit.
Amazon Elastic MapReduce	0,71	Cluster de calcul pour le traitement des données massives.
Autres (Others)	0,28	Services divers et frais annexes de la plateforme.
Total Général	117,95	Budget total consolidé observé en dollars sur la période de juillet 2026.

Pour synthétiser la validation de l'architecture, la matrice ci-dessous met en relation les exigences non fonctionnelles initiales avec les résultats réels mesurés en production :



TABLEAU 3.3 – Matrice d'évaluation technique et financière finale du système

Exigence initiale	Résultat cible attendu	Mesure réelle constatée
Scalabilité	Traitement de gros volumes d'images sans crash	Zéro échec d'exécution, calcul parallèle stable sur 4 Workers.
Faible Latence	Temps de réponse d'inférence sous les 100 ms	Latence moyenne mesurée à 45 ms sur le point de terminaison.
Sécurité	Chiffrement total et isolation logique	Chiffrement KMS actif au repos/transit, VPC privé sans exposition publique.
Supervision	Logs d'erreurs et CPU centralisés	Centralisation opérationnelle et fonctionnelle dans CloudWatch.
Optimisation FinOps	Coût mensuel global maîtrisé et suivi	Coût mensuel total mesuré à 117,95 \$ selon la console de gestion Billing.

3.5 Résumé du chapitre

Ce chapitre a permis de concrétiser l'architecture hybride conçue pour répondre aux défis de volumétrie et de pérennisation du modèle de vision par ordinateur. À travers une démarche d'implémentation rigoureuse sur le Cloud AWS, nous avons validé les aspects clés suivants :

- **L'automatisation et la sécurité** : L'infrastructure a été entièrement provisionnée par code via **Terraform** et déployée de manière fluide à l'aide de pipelines **GitHub Actions**. La sécurité des données et des traitements est garantie par un isolement réseau strict au sein d'un **Amazon VPC** privé et par l'application rigoureuse du principe du moindre privilège via des rôles **AWS IAM**.
- **La gouvernance du Data Lake S3** : Le stockage centralisé sous **Amazon S3** a été structuré de manière hermétique pour héberger les images brutes, les descripteurs ACP propres, les artefacts de modèles et les résultats d'inférence, tout en appliquant un chiffrement fort via **AWS KMS**.
- **La puissance du calcul distribué** : La brique de Data Engineering reposant sur **Amazon EMR** et **PySpark** a démontré sa capacité à ingérer et à prétraiter de grands volumes d'images agricoles. L'Analyse en Composantes Principales (ACP) distribuée a permis de réduire efficacement la dimensionnalité des données sans saturer la mémoire vive des instances.
- **L'industrialisation MLOps** : La mise en œuvre d'**Amazon SageMaker** a permis de standardiser le cycle de vie du modèle. Depuis les environnements **SageMaker Studio**, les modèles sont entraînés, versionnés dans le **Model Registry**, validés par le **Lead Data**,





puis exposés de manière fiable sous forme d'API REST résilientes via un **SageMaker Endpoint**.

- **La validation technique et FinOps :** Les tests d'évaluation ont confirmé la viabilité de la solution avec une latence d'inférence moyenne de 45 ms. L'approche FinOps, s'appuyant sur l'éphémérité du cluster EMR et l'utilisation d'instances EC2 Spot, a permis de maintenir une soutenabilité financière avec un budget mensuel global maîtrisé de 117,95 \$.

L'ensemble des exigences fonctionnelles et non fonctionnelles étant désormais implémentées et validées, nous pouvons à présent formuler la conclusion générale de ce travail de recherche et dresser les perspectives d'évolution futures du système.



CONCLUSION GÉNÉRALE

L'objectif principal de ce mémoire était de concevoir et d'implémenter une architecture MLOps Cloud robuste, sécurisée et économiquement viable sur Amazon Web Services (AWS) pour répondre aux défis du passage à l'échelle et de la pérennisation d'un modèle de vision par ordinateur appliqué à la détection d'anomalies sur les cultures agricoles. Avant nos travaux, l'exécution locale et monolithique du modèle se heurtait à des limites physiques critiques, telles que la saturation de la mémoire vive (RAM), l'impossibilité de gérer de fortes volumétries d'images haute résolution et l'absence de suivi de la dérive des données. Pour lever ces verrous d'ingénierie, nous avons mené une démarche rigoureuse structurée en plusieurs étapes clés :

- **Justification et positionnement technologique** : Une analyse approfondie des architectures de référence déployées par les leaders de l'industrie (Netflix, Capital One, Riot Games, Expedia) a permis de dégager un consensus clair : l'obligation de découpler strictement la gestion des données massives (Data Lake, calcul distribué) du cycle de vie du Machine Learning.
- **Conception d'une architecture hybride découpée** : Nous avons conçu un système articulé autour d'un découplage strict entre le stockage et le calcul. Ce système sépare physiquement l'ingénierie des données (Data Engineering sur Amazon EMR et PySpark) de l'orchestration MLOps (Amazon SageMaker).
- **Automatisation de l'infrastructure et CI/CD** : Les fondations de l'environnement Cloud (VPC, sous-réseaux isolés, rôles IAM restrictifs et bucket S3) ont été entièrement codifiées via **Terraform**. Le déploiement continu et la traçabilité des modifications sont gérés par des pipelines automatisés sous **GitHub Actions**.
- **Validation technique et financière (FinOps)** : Les tests d'évaluation en production ont confirmé l'atteinte de l'ensemble des exigences non fonctionnelles. Le cluster éphémère Amazon EMR a parallélisé l'ingestion et l'Analyse en Composantes Principales (ACP) sur les nœuds de calcul sans saturation mémoire. L'inférence en temps réel affiche une latence moyenne de 45 ms sur le point de terminaison SageMaker. Enfin, l'utilisation d'instances EC2 Spot et l'éphémérité du cluster de préparation ont permis d'optimiser les coûts, pour un budget mensuel total parfaitement maîtrisé de 117,95 \$.



Perspectives d'évolution

Bien que l'architecture implémentée réponde parfaitement aux besoins opérationnels et financiers immédiats, ce travail pose les bases de plusieurs perspectives d'ingénierie majeures pour accroître la maturité industrielle de la plateforme :

- **Automatisation du réentraînement continu (Continuous Training) :** À ce jour, la validation et le réentraînement des modèles nécessitent une action manuelle. Une perspective essentielle consiste à implémenter une boucle de rétroaction automatisée pour lutter contre la dérive des données (*Data Drift*). En configurant un test statistique de Kolmogorov-Smirnov (seuil de tolérance $KS > 0.20$) comparant la distribution des nouvelles images agricoles avec le jeu d'entraînement initial, Amazon CloudWatch pourra automatiquement déclencher un pipeline de réentraînement via Amazon SageMaker Pipelines dès qu'une dégradation de la pertinence algorithmique est mesurée.
- **Orchestration avancée des workflows :** L'intégration d'un orchestrateur externe tel qu'**Apache Airflow** permettrait d'unifier la logique d'exécution de bout en bout. Cet outil permettrait d'enchaîner automatiquement l'allumage du cluster Amazon EMR, l'exécution du script PySpark, la génération des datasets ACP sur S3, puis le déclenchement du job d'apprentissage sur SageMaker sans aucune intervention humaine.
- **Gouvernance et audit de sécurité approfondis :** Pour se conformer aux exigences réglementaires et renforcer la protection des données propriétaires, l'intégration d'**Amazon Macie** pourrait être envisagée afin de découvrir et protéger automatiquement d'éventuelles informations sensibles au sein du Data Lake. De plus, l'intégration d'**AWS KMS** avec des clés gérées par le client pourrait être étendue à l'ensemble des journaux d'exécution système.

En conclusion, ce projet démontre qu'une transition maîtrisée vers le Cloud Computing, guidée par les méthodologies du MLOps et du FinOps, permet de transformer un modèle expérimental local en une plateforme industrielle hautement disponible, scalable et financièrement soutenable, ouvrant la voie à une exploitation pérenne de l'intelligence artificielle dans le secteur agricole.



RÉFÉRENCES BIBLIOGRAPHIQUES

- [1] Lavanya SHANMUGAM, Kumaran THIRUNAVUKKARASU, Jesu Narkarunai Arasu MALAIYAPPAN et Sanjeev PRAKASH. “Scalable Cloud Architectures for Distributed Machine Learning: A Comparative Analysis”. In : *International Journal for Multidisciplinary Research (IJFMR)* 6.1 (2024). ISSN : 2582-2160.
- [2] Emily CARTER. *A Glossary of MLOps Terms Every CTO Should Understand in 2026*. Visité le 16/07/2026. 2026. URL : <https://hire-aidevelopers.com/blog/mlops-glossary-for-ctos-2026/>.
- [3] Christoph WINDHEUSER et Danilo SATO. *MLOps: Continuous Delivery for Machine Learning on AWS*. Rapp. tech. ThoughtWorks / Amazon Web Services, 2020.
- [4] AWS EVENTS. *AWS re:Invent 2020: Designing better ML systems: Learnings from Netflix*. Vidéo YouTube, visité le 18/07/2026. 2020. URL : https://www.youtube.com/watch?v=netflix_reinvent.
- [5] Youssef SOUATI. “AwalTiraWhisper: An MLOps End-to-End Production-Ready Pipeline”. Capstone Design Final Report. Al Akhawayn University - School of Science & Engineering, 2025.
- [6] D. SCULLEY et al. “Hidden Technical Debt in Machine Learning Systems”. In : *Advances in Neural Information Processing Systems (NIPS)*. 2015.
- [7] AMAZON WEB SERVICES. *Machine Learning Lens - AWS Well-Architected Framework*. Rapp. tech. AWS, 2025.
- [8] Jordan GRUBB et Irene Arroyo DELGADO. *Implement a secure MLOps platform based on Terraform and GitHub*. Visité le 24/07/2026. 2025. URL : <https://aws.amazon.com/blogs/machine-learning/implement-a-secure-mlops-platform-based-on-terraform-and-github/>.
- [9] Dominik KREUZBERGER, Niklas KÜHL et Sebastian HIRSCHL. “Machine Learning Operations (MLOps): Overview, Definition, and Architecture”. In : *IEEE Access* 11 (2023).
- [10] AMAZON WEB SERVICES. *Riot Games Success Story - Scaling global game infrastructure using AWS Local Zones*. Visité le 25/07/2026. 2026. URL : <https://aws.amazon.com/solutions/case-studies/riot-games-local-zones-case-study/>.

-
- [11] Srikanth JONNAKUTI. “ENABLING AI-FIRST PRODUCT DESIGN: A SCALABLE CLOUD FOUNDATION FOR ML-DRIVEN INNOVATION”. In : *International Journal of Engineering Technology Research & Management (IJETRM)* 07.06 (2023). ISSN : 2456-9348.
- [12] Rakib HOSSAIN et al. “Ethical and Explainable AI in Reusable MLOps Pipelines”. In : *arXiv* (2024).
- [13] AMAZON WEB SERVICES. *Expedia Group on AWS: Case Studies, Videos, Innovator Stories*. Visité le 23/07/2026. 2026. URL : <https://aws.amazon.com/solutions/case-studies/innovators/expedia/>.
- [14] AMAZON WEB SERVICES. *Best practices - AWS Prescriptive Guidance*. Visité le 22/03/2026. 2025. URL : <https://docs.aws.amazon.com/prescriptive-guidance/>.
- [15] Danylo O. HANCHUK et Serhiy O. SEMERIKOV. “Implementing MLOps practices for effective machine learning model deployment: A meta synthesis”. In : *CEUR Workshop Proceedings* 3918 (2025). AREdu 2024 Workshop, paper 404.
- [16] Venkata Surendra REDDY. “MLOps and Continuous ML Delivery Pipelines”. In : *American Research Journal of Computer Science and Information Technology* 8.1 (2025), p. 36-49.
- [17] Yeswanth MUTYA et Shashank MAJETTY. “Engineering Scalable and Adaptive AI Systems: An MLOps-Driven Framework for Innovation in Intelligent Applications”. In : *International Journal of Innovation Studies* 9.1 (2025), p. 1152-1170.
- [18] Aryyama Kumar JANA. “Framework for Automated Machine Learning Workflows: Building End-to-End MLOps Tools for Scalable Systems on AWS”. In : *Journal of Artificial Intelligence, Machine Learning and Data Science* 1.3 (2023), p. 575-579.
- [19] Smarth BEHL, Akaanksha MITRA et Vishal JAIN. “Advancing Machine Learning Operations (MLOps): A Framework for Continuous Integration and Deployment of Scalable AI Models in Dynamic Environments”. In : *Journal of Information Systems Engineering and Management* 10.2 (2025). ISSN : 2468-4376.
- [20] Sergio MORESCHINI, David HÄSTBACKA et Davide TAIBI. “Comparing Cloud-Native MLOps Platforms: AWS, Azure, GCP, and Databricks”. In : *IEEE Software* 43 (2026).
- [21] Diego NOGARE, Ismar Frango SILVEIRA et Leandro Augusto SILVA. “Towards a New MLOps Architecture: A Methodological Approach Driven by Business and Scientific Requirements”. In : *Brazilian Journal of Software Engineering (CBSOFT)* (2026). Validation en production réelle à l’Itaú Unibanco.
- [22] Iago Águila CIFUENTES. “Design and Development of an MLOps Framework”. Master’s Thesis. Universitat Politècnica de Catalunya (UPC), 2023.
- [23] AMAZON WEB SERVICES. *Netflix Case Study*. Visité le 25/07/2026. 2026. URL : <https://aws.amazon.com/solutions/case-studies/netflix-case-study/>.
-



- [24] AWS EVENTS. *AWS re:Invent 2024 - AI-driven value: Capital One's path to better customer experience (AIM130)*. Vidéo YouTube, visité le 20/07/2026. 2024. URL : https://www.youtube.com/watch?v=capitalone_reinvent.
- [25] CLOUD CONSULTING EUROPE GMBH (CCE). *Expedia case study - Above the clouds*. Visité le 21/07/2026. 2021. URL : <https://www.cloud-consulting.eu/>.
- [26] Romina SHARIFPOUR et Pooya VAHIDI. *Build an end-to-end MLOps pipeline using Amazon SageMaker Pipelines, GitHub, and GitHub Actions*. Visité le 22/07/2026. 2023. URL : <https://aws.amazon.com/blogs/machine-learning/build-an-end-to-end-mlops-pipeline-using-amazon-sagemaker-pipelines-github-and-github-actions/>.

